

Jak poznáme, že je model dobrý?

Podkladové čtenářské materiály k přednášce

1. října 2026

Obsah

1 Co už s daty umíme udělat?	2
2 Co se v této lekci naučíte	2
3 Jeden řádek tabulky představuje jeden strom	2
4 Jak se výška mění s průměrem kmene?	6
5 Jak vztah popíšeme jedním lineárním modelem?	8
6 Co už umíme přechíst ze <code>summary()</code> ?	9
7 Co model přehlíží?	10
8 Je jeden model jedinou rozumnou možností?	12
9 Tři modely vyjadřují tři biologické představy	12
10 Který model prochází nejbližší pozorovaným stromům?	13
11 Jak poznáme, který model je lepší?	13
12 Co už víme o residuích a jejich čtvercích?	14
13 Je přímka lepší než předpověď průměrem?	14
14 Jak velké jsou rozdíly výšek před použitím prediktorů?	15
15 Kolik rozdílů zůstalo po odhadnutí přímky?	16
16 Jakou část variability zachytil model?	17
17 Dostaneme stejné R^2 také ze <code>summary()</code> ?	18
18 Co nám R^2 říká — a co ne?	18
19 Proč R^2 po přidání členu neklesne?	19
20 Které koeficienty jednotlivé modely odhadují?	20
21 Stačí zlepšení R^2 na další koeficienty?	20
22 Kdy může adjustované R^2 klesnout?	21
23 Jak vyvážit shodu a jednoduchost modelu?	22
24 Jak AIC vyjadřuje úspornost modelu?	22
25 Co nám říkají rozdíly AIC mezi kandidáty?	22
26 Ukazují R^2 , adjustované R^2 a AIC na stejný model?	24
27 Stačí dobré skóre k tomu, aby byl model dobrý?	25
28 Který model lze pro tyto stromy nejlépe obhájit?	27
29 Jak porovnávat modely bez automatického hledání?	28
Shrnutí	29
Slovníček pojmů	29

Hlavní otázka

Jaké důkazy potřebujeme, abychom mohli obhájit, že model je pro naši biologickou otázku dobrý?

1 Co už s daty umíme udělat?

Při analýze dat už umíme propojit několik kroků: data prohlédnout, zobrazit, položit biologickou otázku, odhadnout model, interpretovat jeho výstup a zkontrolovat jeho předpoklady.

Sestavte pracovní postup

V jakém pořadí byste použili kroky **prohlédnout data**, **zobrazit vztah**, **formulovat model**, **interpretovat výstup** a **zkontrolovat residua**? Než budete pokračovat, sestavte si vlastní pořadí.

Jedna obhajitelná cesta je položit biologickou otázku, prohlédnout a zobrazit data, formulovat model, interpretovat jeho výstup a zkontrolovat residua. Jednotlivé kroky se mohou opakovat: diagnostika nás například může vrátit k biologické otázce nebo k formulaci modelu. V této lekci známý postup použijeme na nový soubor dat a rozšíříme jej o porovnání několika modelů.

2 Co se v této lekci naučíte

Po absolvování lekce budete umět:

- vypočítat a vysvětlit koeficient determinace R^2 (*coefficient of determination*) z celkového součtu čtverců a součtu čtverců residuí;
- vypočítat a interpretovat adjustované R^2 (*adjusted R-squared*);
- použít Akaikeho informační kritérium (*Akaike information criterion*, AIC) k relativnímu porovnání předem zdůvodněných modelů;
- vysvětlit, proč nejvyšší R^2 automaticky neznamená nejlepší model;
- sestavit malou sadu biologicky zdůvodněných kandidátních modelů;
- obhájit volbu modelu pomocí biologické otázky, složitosti, diagnostiky a interpretovatelnosti.

3 Jeden řádek tabulky představuje jeden strom

Budeme pracovat s měřením jehličnanů. Každý řádek dat představuje jeden strom. Pro tuto lekci využijeme druh stromu, průměr kmene měřený ve výšce 1,3 m a výšku stromu.

```
# Načteme připravenou výukovou tabulku
data_stromy <-
  read.csv(
    file = here::here("data", "allometrie_stromu.csv"),
```

```

    stringsAsFactors = FALSE,
    check.names = FALSE
  )

# Druh stromu převedeme na kategoriální proměnnou
data_stromy$druh_stromu <-
  factor(x = data_stromy$druh_stromu)

```

Tabulka obsahuje 63 stromů a 3 druhy. Nejprve zkontrolujeme několik řádků, strukturu proměnných, chybějící hodnoty a zastoupení druhů.

```

# Prohlédneme první řádky proměnných použitých v modelu
head(
  x = data_stromy[
    ,
    c(
      "druh_stromu",
      "prumer_kmene_cm",
      "vyska_stromu_m"
    )
  ],
  n = 6
)

```

	druh_stromu	prumer_kmene_cm	vyska_stromu_m
1	Pseudotsuga menziesii	54.61	27.04
2	Pseudotsuga menziesii	34.80	27.42
3	Pseudotsuga menziesii	24.89	21.23
4	Pseudotsuga menziesii	28.70	24.96
5	Pseudotsuga menziesii	34.80	29.99
6	Pseudotsuga menziesii	37.85	28.07

```

# Ověříme datové typy a počet chybějících hodnot
str(object = data_stromy)

```

```

'data.frame':  63 obs. of  5 variables:
 $ druh_stromu      : Factor w/ 3 levels "Pinus monticola",...: 3 3 3 3 3 3 3 3 3 3 3 ...
 $ prumer_kmene_cm  : num  54.6 34.8 24.9 28.7 34.8 ...
 $ vyska_stromu_m   : num  27 27.4 21.2 25 30 ...

```

```
$ plocha_listu_m2 : num 338.49 122.16 3.96 86.35 63.35 ...
$ hmotnost_vetvi_kg: num 410.25 83.65 3.51 73.13 62.39 ...
```

```
colSums(x = is.na(data_stromy))
```

```
      druh_stromu   prumer_kmene_cm   vyska_stromu_m   plocha_listu_m2
      0             0                0                0
hmotnost_vetvi_kg
      0
```

```
# Zkontrolujeme počet stromů jednotlivých druhů
table(data_stromy$druh_stromu, useNA = "ifany")
```

```
      Pinus monticola      Pinus ponderosa Pseudotsuga menziesii
      19                22                22
```

```
# Zkontrolujeme rozsahy průměru a výšky
range(
  x = data_stromy$prumer_kmene_cm,
  na.rm = TRUE
)
```

```
[1] 4.83 73.66
```

```
range(
  x = data_stromy$vyska_stromu_m,
  na.rm = TRUE
)
```

```
[1] 3.57 44.99
```

```
# Porovnáme rozsahy průměru kmene mezi druhy
tapply(
  X = data_stromy$prumer_kmene_cm,
  INDEX = data_stromy$druh_stromu,
  FUN = range,
```

```
na.rm = TRUE
)
```

```
$`Pinus monticola`  
[1] 6.48 73.66
```

```
$`Pinus ponderosa`  
[1] 4.83 70.61
```

```
$`Pseudotsuga menziesii`  
[1] 5.33 69.85
```

Průměry kmenů sahají od 4.8 do 73.7 cm a výšky od 3.6 do 45.0 m. Rozsahy průměru kmene jednotlivých druhů se překrývají, takže druhy můžeme porovnávat alespoň v části společného rozsahu. Hodnoty jsou pro měřené stromy věrohodné; nevidíme záporné hodnoty ani zjevnou chybu jednotek.

Doplňující: původ dat

Data pocházejí z objektu `allometry` v balíčku `lgrdata`, verze 0.1.1. Měření jsou připisována Johnu Marshallovi z University of Idaho a byla zveřejněna pod licencí CC0. Pokud je tato verze balíčku `lgrdata` nainstalovaná, původní tabulku lze načíst přímo z něj; není třeba stahovat ani rozbalovat archiv. Následující kód ověří verzi balíčku, načte původní tabulku, přejmenuje proměnné a uloží soubor použitý v této lekci.

```
# Ověříme verzi zdrojového balíčku
stopifnot(
  as.character(
    x = packageVersion(pkg = "lgrdata")
  ) == "0.1.1"
)

# Načteme původní objekt z balíčku
data(
  list = "allometry",
  package = "lgrdata"
)

data_allometry_source <- allometry

# Přeložíme zkratky druhů a vybereme výukové proměnné
vec_nazvy_druhu <-
```

```

c(
  "PIMO" = "Pinus monticola",
  "PIPO" = "Pinus ponderosa",
  "PSME" = "Pseudotsuga menziesii"
)

data_allometry_teaching <-
  data.frame(
    druh_stromu = unname(
      obj = vec_nazvy_druhu[
        as.character(x = data_allometry_source$species)
      ]
    ),
    prumer_kmene_cm = data_allometry_source$diameter,
    vyska_stromu_m = data_allometry_source$height,
    plocha_listu_m2 = data_allometry_source$leafarea,
    hmotnost_vetvi_kg = data_allometry_source$branchmass
  )

# Ověříme počet řádků a chybějící hodnoty
stopifnot(
  nrow(data_allometry_teaching) ==
    nrow(data_allometry_source),
  !anyNA(data_allometry_teaching)
)

# Uložíme stejnou tabulku, jakou načítá tato lekce
write.csv(
  x = data_allometry_teaching,
  file = here::here("data", "allometrie_stromu.csv"),
  row.names = FALSE,
  fileEncoding = "UTF-8"
)

```

4 Jak se výška mění s průměrem kmene?

Vztah dvou numerických proměnných zobrazíme pomocí bodového grafu (anglicky scatter plot). Barva rozlišuje druh stromu, ale každý bod stále představuje jeden konkrétní strom.

```

# Barvy druhů budeme používat stejně ve všech grafech
vec_barvy_druhu <-

```


```

c(
  "Pinus monticola" = "#0072B2",
  "Pinus ponderosa" = "#D55E00",
  "Pseudotsuga menziesii" = "#5D2890"
)

# Zobrazíme vztah průměru kmene a výšky stromu
plot(
  x = data_stromy$prumer_kmene_cm,
  y = data_stromy$vyška_stromu_m,
  col = vec_barvy_druhu[data_stromy$druh_stromu],
  pch = 19,
  xlab = "Průměr kmene ve výšce 1,3 m (cm)",
  ylab = "Výška stromu (m)"
)

legend(
  x = "topleft",
  legend = names(vec_barvy_druhu),
  col = vec_barvy_druhu,
  pch = 19,
  bty = "n"
)

```



Obrázek 1: Výška stromu v závislosti na průměru kmene. Barva rozlišuje druhy stromů.

Co vidíte v datech?

Popište nejsilnější společný vzorec a jednu vlastnost grafu, kvůli které by jediná přímka nemusela stačit.

Výška se s rostoucím průměrem kmene většinou zvětšuje. Barvy druhů však v některých částech grafu leží v odlišných výškových pásmech, takže jedna společná přímka může přehlížet rozdíly mezi druhy.


5 Jak vztah popíšeme jedním lineárním modelem?

Jako první pokus použijeme lineární model, který výšku všech stromů popíše jednou společnou přímkou. Odezvou je výška stromu a prediktorem je průměr kmene.

```
# Odhadneme jednu společnou přímku pro všechny stromy
mod_spolecny <-
  lm(
    formula = vyska_stromu_m ~ prumer_kmene_cm,
    data = data_stromy
  )

# Přidáme odhadnutou přímku do grafu
plot(
  x = data_stromy$prumer_kmene_cm,
  y = data_stromy$vyska_stromu_m,
  col = vec_barvy_druhu[data_stromy$druh_stromu],
  pch = 19,
  xlab = "Průměr kmene ve výšce 1,3 m (cm)",
  ylab = "Výška stromu (m)"
)

abline(
  reg = mod_spolecny,
  col = "#2E2E2E",
  lwd = 3
)
```



Tento model záměrně ignoruje druh stromu a popisuje všechny stromy jedinou přímkou.

6 Co už umíme přečíst ze `summary()`?

Výstup `summary()` obsahuje části, se kterými už umíme pracovat, i dva dosud nevysvětlené řádky. Prohlédněte si celý výpis a zkuste je rozlišit.

```
# Zobrazíme úplný souhrn odhadnutého modelu
summary(object = mod_spolecny)
```

```
Call:
lm(formula = vyska_stromu_m ~ prumer_kmene_cm, data = data_stromy)

Residuals:
    Min       1Q   Median       3Q      Max
-12.4226  -5.3191   0.7425   4.6637  10.5197

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   7.59674    1.47310   5.157 2.88e-06 ***
prumer_kmene_cm 0.51791    0.03647  14.201 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.548 on 61 degrees of freedom
Multiple R-squared:  0.7678,    Adjusted R-squared:  0.764
F-statistic: 201.7 on 1 and 61 DF,  p-value: < 2.2e-16
```

Známé a nové části výstupu

Které části výstupu už dokážete interpretovat? Které dva řádky zatím představují nové otázky?


Už umíme číst volání modelu, souhrn residuí a tabulku koeficientů s jejich nejistotou. Novými otázkami zůstává význam řádků **Multiple R-squared** a **Adjusted R-squared**.

7 Co model přehlíží?

Z předchozích lekcí už známe residua: rozdíly mezi pozorovanými a modelem odhadnutými hodnotami. Vhodný model by v nich neměl zanechávat snadno rozpoznatelný systematický vzorec. Zde se proto neptáme, co residuum znamená, ale zda společná přímka přehlíží rozdíl mezi druhy.

```
# Zobrazíme residua a zachováme barvy druhů
plot(
  x = fitted(object = mod_spolecny),
  y = residuals(object = mod_spolecny),
  col = vec_barvy_druhu[data_stromy$druh_stromu],
  pch = 19,
  xlab = "Odhadnutá výška stromu (m)",
  ylab = "Residuum (m)"
)


abline(
  h = 0,
  col = "#2E2E2E",
  lty = 2
)
```



Obrázek 2: Residua společného modelu podle odhadnuté výšky. Barva znovu rozlišuje druh stromu.

```
# Porovnáme residua s očekáváním normálního rozdělení
qqnorm(
  y = residuals(object = mod_spolecny),
  pch = 19
)

qqline(
  y = residuals(object = mod_spolecny),
  col = "#D55E00",
  lwd = 2
)
```



Obrázek 3: Q-Q graf residuí společného modelu.

Detektivní práce s residui

Zůstává v residuích společného modelu rozdíl mezi druhy? Co by takový vzorec znamenal pro jednu společnou přímku?

8 Je jeden model jedinou rozumnou možností?

Společná přímka odpovídá jedné biologické představě: stejně silné stromy mají podle modelu stejnou odhadnutou výšku bez ohledu na druh. Pozorovaný graf a residua ale připouštějí také rovnoběžné přímky jednotlivých druhů nebo přímky s rozdílnými sklony.

9 Tři modely vyjadřují tři biologické představy

Každý kandidátní model vyjadřuje jinou představu o vztahu průměru kmene, druhu stromu a jeho výšce.


Kandidát	Vzorec v R	Biologická představa
Společná přímka	<code>vyska_stromu_m ~ prumer_kmene_cm</code>	Všechny druhy sdílejí stejný intercept i sklon.
Posun mezi druhy	<code>vyska_stromu_m ~ prumer_kmene_cm + druh_stromu</code>	Druhy mohou mít odlišnou výšku při stejném průměru, ale sdílejí sklon.
Různé sklony	<code>vyska_stromu_m ~ prumer_kmene_cm * druh_stromu</code>	Vztah mezi průměrem a výškou se může mezi druhy lišit.

```
# Model 1: jedna společná přímka
mod_spolecny <-
  lm(
    formula = vyska_stromu_m ~ prumer_kmene_cm,
    data = data_stromy
  )

# Model 2: rovnoběžné přímky druhů
mod_aditivni <-
  lm(
    formula = vyska_stromu_m ~
      prumer_kmene_cm +
      druh_stromu,
    data = data_stromy
  )
```

```
# Model 3: druhově specifické sklony
mod_interakce <-
  lm(
    formula = vyska_stromu_m ~
      prumer_kmene_cm *
      druh_stromu,
    data = data_stromy
  )
```

10 Který model prochází nejbližše pozorovaným stromům?



Obrázek 4: Stejná pozorování a tři kandidátní modely. Panely se liší pouze strukturou odhadnutých přímek.

Porovnejte vzdálenosti bodů od přímek

Ve kterém panelu zůstávají mezi pozorovanými body a odhadnutými přímkami nejkratší svislé vzdálenosti?

Podle obrázku procházejí pozorovaným bodům nejbližše přímky v panelu **Různé sklony**. Rozdíly mezi body a přímkami však chceme vyjádřit číslem, ne pouze odhadovat okem.

11 Jak poznáme, který model je lepší?

Při porovnání modelů potřebujeme rozlišit několik druhů důkazů:

- jak těsně model odpovídá pozorovaným datům;

- kolik parametrů potřebuje;
- zda v residuích nezůstává systematický vzorec;
- zda odpovídá biologické otázce;
- zda jeho výsledek dokážeme smysluplně interpretovat.

Žádné jediné číslo neodpoví na všechny tyto otázky.

12 Co už víme o residuích a jejich čtvercích?

Když jsme poprvé hledali přímku, porovnávali jsme kandidáty pomocí součtu čtverců residuů. V další lekci jsme stejnou veličinu označili anglickou zkratkou **RSS** (*residual sum of squares*) a použili ji při výpočtu reziduální směrodatné odchylky. Při porovnání jednoho společného průměru s několika skupinovými průměry jsme také viděli, že složitější model může RSS zmenšit.

RSS proto není nový pojem. V této lekci jej spojíme s druhým součtem čtverců, který popisuje rozdíly mezi pozorovanými výškami ještě před použitím prediktorů.

Vzpomeňte si na význam RSS

Co se stane se součtem čtverců residuů, když odhadnutá přímka prochází blíže pozorovaným bodům?

Čím jsou residua kratší, tím menší jsou jejich čtverce i jejich součet. **Menší RSS proto znamená těsnější shodu modelu s pozorovanými daty.**

13 Je přímka lepší než předpověď průměrem?


Než posoudíme odhadnutou přímku, potřebujeme jednoduchý výchozí způsob odhadu. Pokud bychom o jednotlivých stromech nevěděli nic dalšího, mohli bychom každému přiřadit průměrnou výšku. Tento průměrový model nám umožní popsat, jak moc se pozorované výšky liší ještě před použitím průměru kmene.

Následující výpočet používá šest skutečných stromů z datové tabulky. Malý výběr umožňuje vidět každý krok výpočtu. Hodnoty kandidátních modelů v dalších tabulkách vycházejí ze všech 63 stromů.

	Strom	Průměr kmene (cm)	Výška (m)
1	A	54.61	27.04
11	B	43.69	31.83
22	C	22.35	19.39
32	D	20.83	23.34
43	E	11.94	5.85
58	F	73.66	44.64

14 Jak velké jsou rozdíly výšek před použitím prediktorů?

Průměrná výška šesti stromů je 25.35 m. Svislé úsečky ukazují odchylku každého pozorování od tohoto průměru.



Obrázek 5: Odchylky šesti pozorovaných výšek od jejich průměru. Délky úseček jsou před umocněním kladné nebo záporné odchylky.

Kladné a záporné odchylky by se při prostém součtu vyrušily. Proto je umocníme na druhou a sečteme. Vznikne **celkový součet čtverců** (*total sum of squares*), tedy číselné vyjádření celkové variability pozorovaných výšek kolem jejich průměru.

	Strom	Výška	Odchylka od průměru	Čtverec odchylky
1	A	27.04	1.69	2.86
11	B	31.83	6.48	42.01
22	C	19.39	-5.96	35.50
32	D	23.34	-2.01	4.03
43	E	5.85	-19.50	380.19
58	F	44.64	19.29	372.17

Výpočet nejprve zapíšeme pomocí názvů veličin:

celkový součet čtverců = čtverec odchylky stromu A + ... + čtverec odchylky stromu F .

Hodnoty v následujícím výpočtu jsou druhé mocniny odchylek z posledních dvou sloupců tabulky:

$$\begin{aligned}\text{celkový součet čtverců} &= (1.69)^2 + (6.48)^2 + (-5.96)^2 + (-2.01)^2 + (-19.50)^2 + (19.29)^2 \\ &= 836.76.\end{aligned}$$

Obecně označíme pozorovanou hodnotu y_i , průměr všech pozorovaných hodnot $\bar{y}$ a počet pozorování n :

$$SS_{\text{total}} = \sum_{i=1}^n (y_i - \bar{y})^2.$$

Symbol SS_{total} označuje celkový součet čtverců. Každý člen $y_i - \bar{y}$ je odchylka jedné pozorované výšky od průměrné výšky. Hodnota 836.76 m^2 popisuje celkovou čtvercovou odchylku šesti výšek od jejich průměru.

Který strom přispívá nejvíce?


Najděte v grafu a tabulce strom s největším příspěvkem k celkové variabilitě. Proč o velikosti příspěvku rozhoduje délka úsečky **i její umocnění na druhou**?

Největší příspěvek má strom E, protože má největší absolutní odchylku od průměru. Umocnění zachová příspěvky kladných i záporných odchylek a větší odchylky zvýrazní.

15 Kolik rozdílů zůstalo po odhadnutí přímky?

Průměr nyní nahradíme odhadnutou přímkou. Každá úsečka vede od modelem odhadnuté výšky k pozorované výšce stejného stromu. Její orientovaná délka je známé residuum:

$$\text{residuum} = \text{pozorovaná výška} - \text{odhadnutá výška}.$$



Obrázek 6: Residua stejné šestice stromů. Každá oranžová úsečka spojuje odhadnutou a pozorovanou výšku.

Residuum nese znaménko: bod nad přímkou má kladné residuum, bod pod přímkou záporné. Absolutní hodnota residua udává délku svislé úsečky mezi bodem a přímkou. Čtverec residua znaménko odstraní a určuje příspěvek daného stromu k součtu čtverců residuí.

Čtverce residuí sečteme. Dostaneme již známý součet čtverců residuí (*residual sum of squares*, RSS): kolik čtvercové odchylky zůstalo po odhadnutí modelu.

	Strom	Pozorovaná výška	Odhadnutá výška	Resi- dium	Absolutní hodnota re- sidua	Čtverec resi- dua
1	A	27.04	33.67	-6.63	6.63	43.92
11	B	31.83	28.25	3.58	3.58	12.83
22	C	19.39	17.66	1.73	1.73	3.00
32	D	23.34	16.90	6.44	6.44	41.42
43	E	5.85	12.49	-6.64	6.64	44.12
58	F	44.64	43.12	1.52	1.52	2.31

Výpočet používá čtverce residuí z tabulky:

součet čtverců residuí = čtverec residua stromu A + ... + čtverec residua stromu F .

$$\begin{aligned} \text{součet čtverců residuí} &= (-6.63)^2 + (3.58)^2 + (1.73)^2 + (6.44)^2 + (-6.64)^2 + (1.52)^2 \\ &= 147.60. \end{aligned}$$

Index i označuje pořadí pozorování. Residuum i -tého pozorování označíme jako e_i :

$$SS_{\text{res}} = \sum_{i=1}^n e_i^2.$$

Symbol SS_{res} označuje RSS. Jeho hodnota 147.60 m² je menší než celkový součet čtverců, protože přímka sleduje část rozdílů mezi výškami lépe než samotný průměr. **Celkový součet čtverců a RSS jsou dvě stavební veličiny, které použijeme společně v následujícím výpočtu.**

Residuum, jeho velikost a čtverec

Který strom má číselně nejvyšší residuum? Který strom má residuum s největší absolutní hodnotou, a proto také největší čtverec residua? Jsou to stejné stromy?

Číselně nejvyšší residuum má strom D: 6.44 m. Největší absolutní hodnotu residua má strom E: jeho residuum je -6.64 m, jeho absolutní hodnota je 6.64 m a čtverec residua je 44.12 m². Nejde o stejné stromy. Nejde o chybu: umocnění odstraní znaménko, takže příspěvek k RSS určuje velikost residua bez ohledu na to, zda je kladné, nebo záporné.

16 Jakou část variability zachytil model?

Máme dvě veličiny: celkový součet čtverců před použitím prediktoru a součet čtverců residuí (RSS) po odhadnutí přímky. Jejich poměr říká, jaká část původních rozdílů zůstala nevysvětlena. Jeho doplněk do jedné proto vyjadřuje **zachycený podíl variability**.

Nejprve vztah vyjádříme pouze pomocí veličin, které už známe:

$$\text{zachycený podíl variability} = 1 - \frac{\text{součet čtverců residuí}}{\text{celkový součet čtverců}}.$$

Do vztahu dosadíme všech šest residuí a všech šest odchylek od průměru:

$$\text{zachycený podíl variability} = 1 - \frac{(-6.63)^2 + (3.58)^2 + (1.73)^2 + (6.44)^2 + (-6.64)^2 + (1.52)^2}{(1.69)^2 + (6.48)^2 + (-5.96)^2 + (-2.01)^2 + (-19.50)^2 + (19.29)^2}.$$

Po sečtení čtverců dostaneme:

$$\text{zachycený podíl variability} = 1 - \frac{147.60}{836.76} = 0.824.$$

Tento podíl nazýváme koeficient determinace R^2 (**coefficient of determination, R-squared**). Obecně jej zapíšeme:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{total}}}.$$

Zkratka SS znamená „součet čtverců“. SS_{res} je součet čtverců residuí od odhadnutého modelu. SS_{total} je součet čtverců odchylek pozorované odezvy od jejího průměru.

Vypočítejte a interpretujte

Kdyby $SS_{\text{total}} = 500$ a $SS_{\text{res}} = 125$, jaké by bylo R^2 ? Napište také jednu větu, která výsledek interpretuje pro konkrétní odezvu.

R^2 by bylo $1 - 125/500 = 0.75$. Model by tedy v datech zachytil 75 % variability konkrétní odezvy kolem jejího průměru.

17 Dostaneme stejné R^2 také ze `summary()`?

V malém příkladu jsme mohli rozepsat každý čtverec. Pro všech 63 stromů použijeme stejný výpočet, ale dosadíme už jen oba součty čtverců.

$$R^2 = 1 - \frac{1877.39}{8084.56} = 0.768.$$

Stejnou hodnotu vrátí také `summary(mod_spolecny)$r.squared`: 0.768. Výpis tedy nepřináší jinou definici; pouze za nás provede tentýž výpočet.

18 Co nám R^2 říká — a co ne?

Pro všech 63 stromů je R^2 společné přímky 0.768. Model tedy ve **stejných datech, na kterých byl odhadnut**, zachycuje přibližně 76.8 % pozorované variability výšky kolem jejího průměru.

R^2 však neříká:

- že model správně předpověděl 76.8 % jednotlivých stromů;
- že model splňuje předpoklady;
- že vztah je příčinný;
- že model bude stejně dobrý pro nové stromy.

Která interpretace je obhajitelná?

Vyberte a zdůvodněte jednu možnost:

- **A:** R^2 vyjadřuje podíl správně předpovězených stromů.
- **B:** R^2 vyjadřuje podíl zachycené variability odezvy v těchto datech.
- **C:** R^2 vyjadřuje pravděpodobnost, že je model pravdivý.

Obhajitelná je možnost **B**: R^2 vyjadřuje podíl zachycené variability odezvy v datech použitých k odhadu modelu.

19 Proč R^2 po přidání členu neklesne?

Nyní se vrátíme ke všem 63 stromům. Naše tři kandidátní modely jsou vnořené: složitější model vždy obsahuje všechny možnosti jednoduššího modelu a přidává další koeficienty. Při odhadu metodou nejmenších čtverců tedy může složitější model zopakovat jednodušší řešení, nebo součet čtverců residuí (RSS) ještě zmenšit.

Kandidátní model	Počet koeficientů	Součet čtverců residuí (RSS)	R^2
Společná přímka	2	1877.4	0.768
Posun mezi druhy	4	1674.5	0.793
Různé sklony	6	1643.7	0.797

Vyšší R^2 není automatické vítězství

Nejpružnější kandidát získává nejvyšší R^2 už proto, že má více možností přiblížit se stejným pozorováním. Samotné R^2 neumí rozhodnout, zda malé zlepšení shody stojí za další koeficienty.

Co udělá zbytečný člen?

Představte si, že do modelu přidáme prediktor, který téměř nic nepřinese. Může R^2 klesnout? Dokazuje jeho případné zvýšení, že je nový model užitečnější?

R^2 nemůže klesnout, protože rozšířený model může vždy zopakovat odhady jednoduššího modelu. Případné zvýšení však samo nedokazuje, že jsou nové koeficienty užitečné.

20 Které koeficienty jednotlivé modely odhadují?

Počet koeficientů není abstraktní číslo. Každý z nich odpovídá konkrétní části modelu: interceptu, sklonu nebo rozdílu mezi druhy.

Přiřadte koeficienty k modelům

Než se podíváte na následující seznam, rozhodněte, který model potřebuje pouze intercept a jeden sklon, který přidává rozdíly druhů a který navíc přidává rozdíly ve sklonech.

- **Společná přímka – 2 koeficienty:** (Intercept), `prumer_kmene_cm`.
- **Posun mezi druhy – 4 koeficienty:** (Intercept), `prumer_kmene_cm`, `druh_stromuPinus ponderosa`, `druh_stromuPseudotsuga menziesii`.
- **Různé sklony – 6 koeficienty:** (Intercept), `prumer_kmene_cm`, `druh_stromuPinus ponderosa`, `druh_stromuPseudotsuga menziesii`, `prumer_kmene_cm:druh_stromuPinus ponderosa`, `prumer_kmene_cm:druh_stromuPseudotsuga menziesii`.

Společná přímka má intercept a jeden sklon. Aditivní model přidává dva rozdíly druhů vůči referenčnímu druhu. Interakční model navíc přidává dva rozdíly ve sklonech. Právě tyto konkrétní možnosti navíc mohou zlepšit shodu s daty.

21 Stačí zlepšení R^2 na další koeficienty?

Adjustované R^2 (adjusted R-squared) se ptá, zda je nárůst obyčejného R^2 dostatečně velký vzhledem ke dvěma dalším údajům:

- n je počet pozorování použitých k odhadu modelu;
- k je počet odhadovaných regresních koeficientů **včetně interceptu**.

V našich datech mají všechny modely stejné $n = 63$, ale postupně odhadují 2, 4, 6 koeficientů. Pro aditivní model známe:

- obyčejné $R^2 = 0.793$;
- počet pozorování $n = 63$;
- počet regresních koeficientů $k = 4$.

Úprava vychází z podílu variability, který obyčejné R^2 nezachytilo.

Dosadíme je přímo do výpočtu:

adjustované $R^2 = 1 - (\text{podíl variability nezachycený modelem} \times \text{úprava za počet pozorování a koeficientů})$.

Všechny vstupní hodnoty nyní zapíšeme do stejného vztahu:

$$R_{\text{adj}}^2 = 1 - (1 - 0.793) \times \frac{63 - 1}{63 - 4} = 0.782.$$

Po výpočtu obou částí v závorce dostaneme:

$$R_{\text{adj}}^2 = 1 - (0.207 \times 1.051) = 0.782.$$

Obecná podoba stejného výpočtu je:

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \times \frac{n-1}{n-k}.$$

Faktor $\frac{n-1}{n-k}$ je při přidání koeficientů větší. Pokud nové koeficienty nesníží residuální variabilitu dostatečně, adjustované R^2 se zmenší.

Označte význam každé části

Ve výpočtu výše najdete část popisující shodu modelu, velikost datového souboru a počet odhadovaných koeficientů. Která část se změní, když přidáme interakci?

Shodu vyjadřuje $1 - R^2$, velikost datového souboru představuje n a počet koeficientů představuje k . Po přidání interakce se změní R^2 i k ; počet pozorování n zůstane stejný.

22 Kdy může adjustované R^2 klesnout?

Porovnáme obyčejné R^2 po přidání interakce. Ta přidává další sklony a má smysl jen tehdy, pokud dostatečně změní residua vzhledem k počtu nových koeficientů.

Kandidátní model	Počet koeficientů	R^2	Adjustované R^2
Společná přímka	2	0.768	0.764
Posun mezi druhy	4	0.793	0.782
Různé sklony	6	0.797	0.779

Přechod z aditivního modelu k interakčnímu přidá dva sklony. Obyčejné R^2 se zvýší z 0.793 na 0.797, ale adjustované R^2 klesne z 0.782 na 0.779. Zisk ve shodě je pro tuto úpravu příliš malý.

Předpověď před výsledkem

Kdyby nový koeficient téměř nezměnil residua, co se stane s obyčejným a adjustovaným R^2 ? Vysvětlíte obě odpovědi pomocí jejich výpočtu.

Obyčejné R^2 se nezmenší, protože RSS se po přidání koeficientu nemůže zvětšit. Adjustované R^2 však pravděpodobně klesne: téměř stejný nezachycený podíl se násobí větší úpravou za počet koeficientů.

23 Jak vyvážit shodu a jednoduchost modelu?

R^2 hodnotí shodu s pozorovanými daty, ale nezvýhodňuje jednodušší vysvětlení. Při porovnání modelů proto používáme také **princip úspornosti (parsimony)**: složitější model má být upřednostněn jen tehdy, když přinese dostatečné zlepšení shody.

Kdy stojí složitost za to?

Dva modely popisují stejná data téměř stejně dobře, ale jeden potřebuje 2 koeficienty a druhý 6. Který byste předběžně upřednostnili a jakou další informaci byste chtěli znát?

Předběžně bychom upřednostnili jednodušší model. Potřebujeme však posoudit, zda malé zlepšení shody složitějšího modelu vyváží 4 koeficienty navíc.

24 Jak AIC vyjadřuje úspornost modelu?

Akaikeho informační kritérium (Akaike information criterion, AIC) je alternativní způsob porovnání kandidátů. V jednom čísle vyvažuje:

- shodu modelu s pozorovanými daty;
- penalizaci za složitost modelu.

Lepší shoda AIC snižuje, zatímco další odhadované veličiny je zvyšují. Proto při srovnání stejných dat preferujeme **nižší AIC**. AIC nevyjadřuje podíl variability a nemá stejnou škálu jako R^2 .

25 Co nám říkají rozdíly AIC mezi kandidáty?

Hodnotu AIC jednoho modelu získáme přímo funkcí `AIC()`:

```
# Vypočítáme AIC společné přímky  
AIC(object = mod_spolecny)
```

```
[1] 398.64
```

Samotné AIC 398.64 nelze označit za „dobré“ nebo „špatné“. Jde o relativní kritérium: číslo získává význam až ve srovnání předem určených kandidátů.

Porovnávané modely přitom musí používat:

- stejnou odezvu;
- stejná pozorování;
- stejný způsob pravděpodobnostního popisu residuí — zde u všech kandidátů předpokládáme residua s normálním rozdělením a stejnou základní strukturou.

Od AIC každého kandidáta odečteme nejnižší AIC v celé sadě. Vztah nejprve zapíšeme pouze názvy veličin:

rozdíl od nejnižší AIC = AIC kandidáta – nejnižší AIC v sadě .

Pro společnou přímku dosadíme její AIC a nejnižší AIC ze tří kandidátů:

$$\text{rozdíl od nejnižší AIC} = 398.64 - 395.44.$$

Po odečtení dostaneme:

$$\text{rozdíl od nejnižší AIC} = 3.20.$$

Tento rozdíl se často označuje jako ΔAIC (delta AIC).

Obecně jej zapíšeme:

$$\Delta AIC_i = AIC_i - AIC_{\min}.$$

Symbol i označuje konkrétní kandidátní model, AIC_i jeho hodnotu AIC a $AIC_{\min}$ nejnižší AIC v celé kandidátní sadě. Nejlépe podporovaný kandidát má ΔAIC rovné 0; ostatní hodnoty ukazují, o kolik je jejich AIC větší. V této lekci záměrně nepoužíváme univerzální práh, který by rozhodnutí automatizoval.

Kandidátní model	AIC	Rozdíl od nejnižší AIC (ΔAIC)
Společná přímka	398.64	3.20
Posun mezi druhy	395.44	0.00
Různé sklony	398.27	2.83

Proč nestačí jedno číslo?

Kolega oznámí: „Můj model má AIC 395, takže je dobrý.“ Jaká informace chybí, abyste mohli jeho tvrzení posoudit?

Chybí AIC dalších modelů odhadnutých pro stejnou odezvu a stejná pozorování. Teprve rozdíly mezi těmito hodnotami umožňují kandidáty porovnat.

Nejlepší kandidát nemusí být dobrý model

Porovnání vybírá nejlépe podporovaný model **pouze z modelů, které jsme zařadili do kandidátní sady**. Neříká, že je tento model obecně dobrý ani že jsme našli nejlepší možný popis dat. Jiný model, který jsme vůbec neposuzovali, může stejná data popsat podstatně lépe.

Doplňující: Jak R vypočítá AIC?

Výpočet AIC používá pravděpodobnostní shodu modelu s daty a penalizaci za počet odhadovaných veličin. Podrobný výpočet budeme potřebovat až v navazujících tématech; v této lekci stačí porovnání vrácené funkcí `AIC()`.

```
# Vypočítáme AIC všech předem definovaných kandidátů
data.frame(
  model = c(
    "Společná přímka",
    "Posun mezi druhy",
    "Různé sklony"
  ),
  AIC = c(
    AIC(object = mod_spolecny),
    AIC(object = mod_aditivni),
    AIC(object = mod_interakce)
  )
)
```

```
      model      AIC
1 Společná přímka 398.6400
2 Posun mezi druhy 395.4366
3   Různé sklony 398.2656
```

26 Ukazují R^2 , adjustované R^2 a AIC na stejný model?

Každá míra zachází se shodou a složitostí jinak. Jejich společná tabulka proto není hlasováním, ale podkladem pro argument.

Kandidátní model	Počet koeficientů	R^2	Adjustované R^2	AIC
Společná přímka	2	0.768	0.764	398.64
Posun mezi druhy	4	0.793	0.782	395.44
Různé sklony	6	0.797	0.779	398.27

Čtete tabulku jako argument

Který model má nejvyšší R^2 ? Který má nejvyšší adjustované R^2 a nejnižší AIC? Vysvětlete neshodu pomocí toho, jak každá míra zachází se shodou a složitostí, ne jako tři rovnocenné hlasy o tom, který model je „pravdivý“.


Interakční model má nejvyšší R^2 , protože má nejvíce možností přizpůsobit se datům. Aditivní model má nejvyšší adjustované R^2 a nejnižší AIC, protože dodatečné sklony interakčního modelu nepřinesly dostatečné zlepšení shody. Žádná z těchto hodnot neudává pravděpodobnost, že je model pravdivý.

27 Stačí dobré skóre k tomu, aby byl model dobrý?

Srovnávací skóre nenahrazuje diagnostiku modelu. U kandidáta podporovaného adjustovaným R^2 a AIC kontrolujeme vztah residuí k odhadnutým hodnotám, Q-Q graf a vliv jednotlivých pozorování.

```
# Zkontrolujeme, zda se rozptyl residuí systematicky mění
plot(
  x = fitted(object = mod_aditivni),
  y = residuals(object = mod_aditivni),
  col = vec_barvy_druhu[data_stromy$druh_stromu],
  pch = 19,
  xlab = "Odhadnutá výška stromu (m)",
  ylab = "Residuum (m)"
)


abline(
  h = 0,
  col = "#2E2E2E",
  lty = 2
)
```



Obrázek 7: Residua aditivního modelu podle odhadnuté výšky.

```
# Zkontrolujeme tvar rozdělení residuí
qqnorm(
  y = residuals(object = mod_aditivni),
  pch = 19
)

qqline(
  y = residuals(object = mod_aditivni),
  col = "#D55E00",
  lwd = 2
)
```



Obrázek 8: Q–Q graf residuí aditivního modelu.

Z předchozích lekcí také známe otázku, zda některé pozorování model neovlivňuje neobvykle silně. Cookova vzdálenost (Cook's distance) shrnuje, jak silně by se odhadnuté hodnoty změnily po vynechání jednoho pozorování. Orientační čára $4/n$ není automatický test; pouze označuje stromy, které si zaslouží bližší kontrolu.

```
# Vypočítáme vliv jednotlivých pozorování
vec_cookova_vzdalenost <-
  cooks.distance(model = mod_aditivni)

hranice_cook <-
  4 / nobs(object = mod_aditivni)


# Zobrazíme, která pozorování mají největší vliv
plot(
  x = vec_cookova_vzdalenost,
```

```

type = "h",
lwd = 2,
xlab = "Pořadí stromu v tabulce",
ylab = "Cookova vzdálenost"
)

abline(
  h = hranice_cook,
  col = "#D55E00",
  lty = 2,
  lwd = 2
)

```



Obrázek 9: Cookovy vzdálenosti pro aditivní model. Přerušovaná čára zobrazuje orientační hodnotu $4/n$.

Nad orientační čarou leží 4 pozorování. To není důvod je odstranit; je to důvod vrátit se k jejich měření, biologickému významu a vlivu na závěr.

Rozhodnutí po kontrole modelu

Podporují graf residuí, Q-Q graf a Cookovy vzdálenosti závěr ze srovnávací tabulky, nebo vyžadují opatrnější formulaci? Uveďte jeden důvod pro zvolený model a jedno omezení.

28 Který model lze pro tyto stromy nejlépe obhájit?

Aditivní model s průměrem kmene a druhem stromu představuje pro tato data nejlépe obhajitelný model **ze tří posuzovaných kandidátů**. Oproti jedné společné přímce zachytí rozdíly mezi

druhy. Interakční model sice dosáhne nejvyššího R^2 , ale jeho dodatečné sklony nepřinesou dostatečný zisk podle adjustovaného R^2 ani AIC.

Tento závěr zůstává podmíněný. Neříká, že je aditivní model nejlepší ze všech možných modelů. Data navíc obsahují omezený počet stromů, Q-Q graf není dokonale přímý a pozorovací studie sama nedokládá příčinný efekt druhu.

Odpověď na hlavní otázku

Dobrý model nepoznáme podle jediného čísla. Obhajoba musí propojit biologickou otázku, shodu s daty, složitost, diagnostiku, interpretovatelnost a omezení dat.

29 Jak porovnávat modely bez automatického hledání?

1. Položte biologickou otázku.
2. Prohlédněte a zobrazte data.
3. Definujte malou sadu biologicky zdůvodněných kandidátů.
4. Použijte pro všechny kandidáty stejnou odezvu a stejná pozorování.
5. Porovnejte odhadnuté vztahy, residua, R^2 , adjustované R^2 a AIC.
6. Zkontrolujte předpoklady a vlivná pozorování.
7. Obhajte závěr a pojmenujte jeho omezení.

Automatické hledání nenahrazuje biologickou otázku

Funkce pro automatické přidávání a odebírání členů mohou vytvořit dlouhý seznam modelů, ale samy neurčí, které modely mají biologický smysl. V této lekci proto nepoužíváme krokový výběr ani vyhledávání všech možných kombinací.

Co když žádný lineární kandidát nestačí?

Pokud všechny kandidátní přímky zanechávají v residuích systematické zakřivení, problém nemusí být jen ve volbě prediktorů. Vztah může být nelineární nebo může vyžadovat transformaci proměnných. Těmto možnostem se budeme věnovat v následující lekci.

Shrnutí

- Model posuzujeme pomocí několika druhů důkazů, nikoli jedním skóre.
- R^2 shrnuje shodu s pozorovanými daty, ale nemůže klesnout po přidání členů do vnořeného lineárního modelu.
- Adjustované R^2 a AIC zohledňují složitost odlišnými způsoby.
- Kandidáty definujeme podle biologické otázky předtím, než porovnáme jejich skóre.
- Konečná obhajoba musí zahrnout také diagnostiku, interpretovatelnost a omezení dat.

Slovníček pojmů

Pojmy použité v těchto materiálech a jejich definice:

Interaktivní slovníček je dostupný online: <https://cuni-natur-biostatistics.github.io/slovník/>