BIOSTATISTIKA

L09

# Jak poznáme, že je model dobrý?




Porovnání kandidátních modelů: $R^2$, adjustované $R^2$ a AIC

cuni-natur-biostatistics.github.io/materialy.html

Ilustrace vytvořená pomocí AI.

# Co vlastně na stromě měříme?



Ilustrace vytvořená pomocí AI.

U každého jehličnanu známe

- **druh stromu** — tři severoamerické jehličnany;
- **průměr kmene** ve výšce 1,3 m (cm);
- **výšku stromu** (m).

## Mají stejně silné stromy různých druhů stejnou výšku?

# Co si pamatujete z minulé lekce?

Odpovězte samostatně na tři krátké otázky. Společné odpovědi projdeme po hlasování.

# Jaký je podle modelu s interakcí rozdíl zadní šířky samec – samice při délce krunýře 30 mm?

**Koeficienty modelu s interakcí: modří krabi**

zadni_sirka_mm ~ delka_krunyre_mm * pohlavi · referenční skupina: samice

| Koeficient | Odhad (mm, mm/mm) |
|---|---|
| (Intercept) | 0,7077 |
| delka_krunyre_mm | 0,4067 |
| pohlavisamec | 1,9731 |
| delka_krunyre_mm:pohlavisamec | −0,1245 |

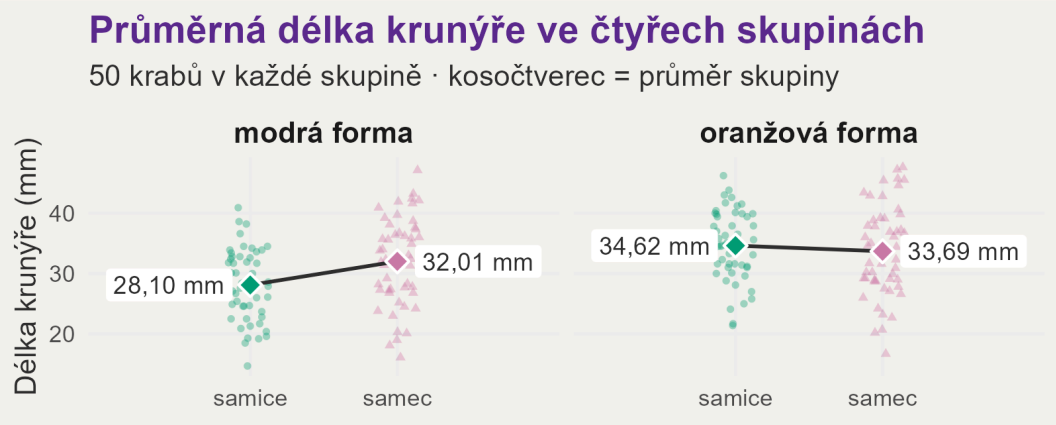
- +1,97 mm
- −0,12 mm
- +5,71 mm
- −1,76 mm

**SPRÁVNÁ ODPOVĚĎ**

: −1,76 mm

Koeficient pohlavisamec platí jen při délce 0 mm. Při 30 mm k němu přičteme 30 × interakční koeficient: 1,973 + 30 × (−0,1245) = −1,76 mm. Samec má tedy při 30 mm užší zadní část krunýře.

# Jakou hodnotu má v modelu forma * pohlavi koeficient formaoranžová:pohlavisamec?




- −4,84 mm
- −0,93 mm
- +3,91 mm
- +6,52 mm

**SPRÁVNÁ ODPOVĚĎ**

: −4,84 mm

Interakce je rozdíl dvou rozdílů: (33,69 − 34,62) − (32,01 − 28,10) = −0,93 − 3,91 = −4,84 mm. O tolik je rozdíl samec − samice u oranžové formy menší než u modré.

# Co platí o přírůstku objemu na 1 cm průměru u stromu vysokého 35 m?

**Koeficienty modelu objemu dřeva**

objem_m3 ~ prumer_cm * vyska_m · 31 stromů
změřené průměry 21,1–52,3 cm, výšky 19,2–26,5 m

| Koeficient | Odhad (m³, m³/cm, m³/m) |
|---|---|
| (Intercept) | 1,96508 |
| prumer_cm | −0,06528 |
| vyska_m | −0,12050 |
| prumer_cm:vyska_m | 0,00493 |

- Je +0,107 m³ na 1 cm; vzorec platí pro každou výšku.
- Je −0,065 m³ na 1 cm; to je koeficient prumer_cm.
- Vyjde +0,107 m³ na 1 cm; 35 m je ale mimo data.
- Nelze ho spočítat; u dvou numerických prediktorů sklon nemá smysl.

**SPRÁVNÁ ODPOVĚĎ**

: Vyjde +0,107 m³ na 1 cm; 35 m je ale mimo data.
Vzorec −0,065 + 35 × 0,00493 dá +0,107 m³ na 1 cm, ale změřené stromy byly vysoké jen 19–27 m. Mimo tento rozsah data tvar vztahu nepodporují, takže číslo je extrapolace, odhad mimo pozorované výšky. Uvnitř dat je sklon např. +0,038 (21 m) a +0,058 (25 m) m³ na 1 cm.

# Výsledky učení

Po absolvování této přednášky budete schopni:

- vypočítat $R^2$ z celkového součtu čtverců a součtu čtverců residuí a vysvětlit, co popisuje;
- vysvětlit, proč nejvyšší $R^2$ automaticky neznamená nejlepší model;
- rozlišit, jak $R^2$, adjustované $R^2$ a AIC zacházejí se shodou a složitostí, a používat AIC jen k relativnímu porovnání;
- sestavit malou sadu biologicky zdůvodněných kandidátních modelů se stejnou odezvou a stejnými pozorováními;
- obhájit volbu modelu pomocí biologické otázky, složitosti, diagnostiky a interpretovatelnosti a pojmenovat její omezení.

# Jedna přímka pro všechny stromy?

# Jeden řádek tabulky představuje jeden strom

```
data_stromy <-
  read.csv(file = "data/allometrie_stromu.csv")

data_stromy$druh_stromu <-
  factor(x = data_stromy$druh_stromu)

vec_promenne <-
  c("druh_stromu", "prumer_kmene_cm", "vyska_stromu_m")

head(
  x = data_stromy[, vec_promenne],
  n = 4
)
```

```
           druh_stromu prumer_kmene_cm vyska_stromu_m
1 Pseudotsuga menziesii           54.61          27.04
2 Pseudotsuga menziesii           34.80          27.42
3 Pseudotsuga menziesii           24.89          21.23
4 Pseudotsuga menziesii           28.70          24.96
```

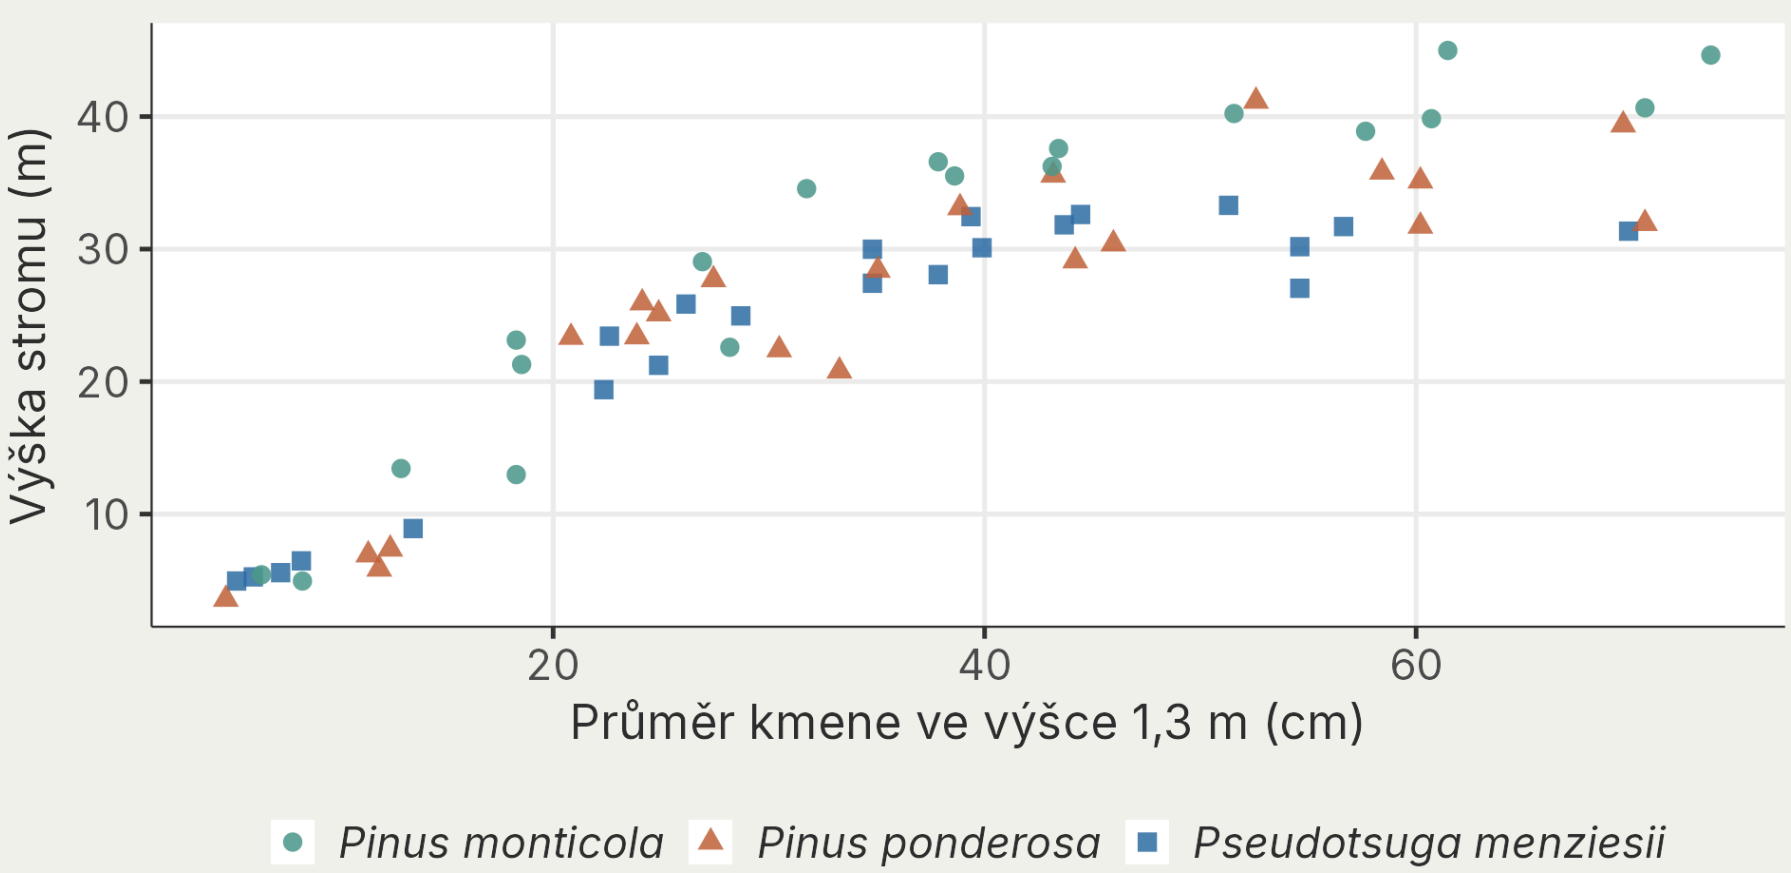
63 stromů

- *Pinus monticola*: 19 stromů
- *Pinus ponderosa*: 22 stromů
- *Pseudotsuga menziesii*: 22 stromů

- chybějící hodnoty: 0
- průměr kmene: 4,8–73,7 cm
- výška: 3,6–45,0 m

Jiné stromy než minule: tři druhy jehličnanů a **výška je tentokrát odezva**.

# Jak se výška mění s průměrem kmene?

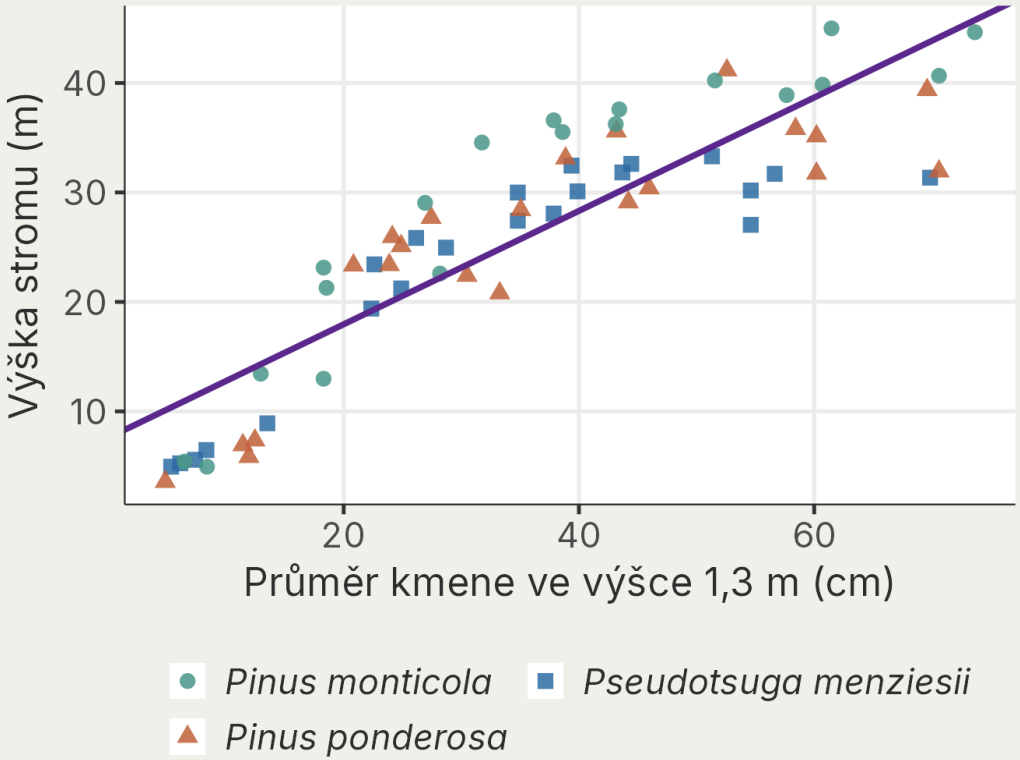



**Ve dvojici:** Jaký vzorec v datech převládá? Co by mohlo vadit jedné přímce pro všechny stromy?

# Jedna společná přímka pro všechny druhy

```
1  mod_spolecny <-
2    lm(
3      formula = vyska_stromu_m ~
4        prumer_kmene_cm,
5      data = data_stromy
6    )
7
8  coef(object = mod_spolecny)
```

```
(Intercept) prumer_kmene_cm
  7.5967386       0.5179077
```




Sklon: o 0,52 m vyšší odhadovaná výška na každý centimetr průměru — stejně pro všechny druhy.

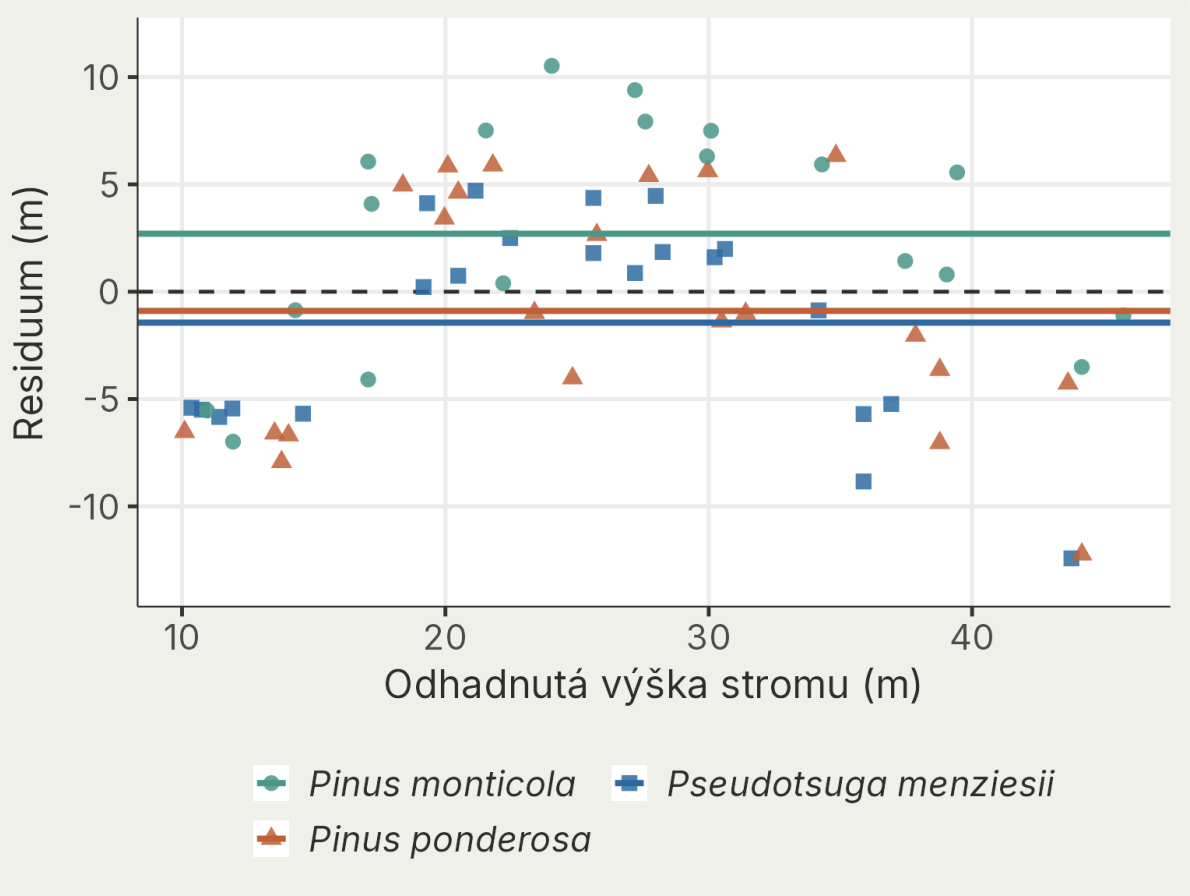
# Co už umíme přečíst ze `summary()`?

```
1 summary(object = mod_spolecny)
```

```
1
2 Call:
3 lm(formula = vyska_stromu_m ~ prumer_kmene_cm, data = data_stromy)
4
5 Residuals:
6      Min       1Q   Median       3Q      Max
7 -12.4226  -5.3191   0.7425   4.6637  10.5197
8
9 Coefficients:
10                Estimate Std. Error t value Pr(>|t|)
11 (Intercept)     7.59674    1.47310   5.157 2.88e-06 ***
12 prumer_kmene_cm  0.51791    0.03647  14.201  < 2e-16 ***
13 ---
14 Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
15
16 Residual standard error: 5.548 on 61 degrees of freedom
17 Multiple R-squared:  0.7678,    Adjusted R-squared:  0.764
18 F-statistic: 201.7 on 1 and 61 DF,  p-value: < 2.2e-16
```

Známe: volání modelu · residua · koeficienty s nejistotou

# Zůstává v residuích rozdíl mezi druhy?



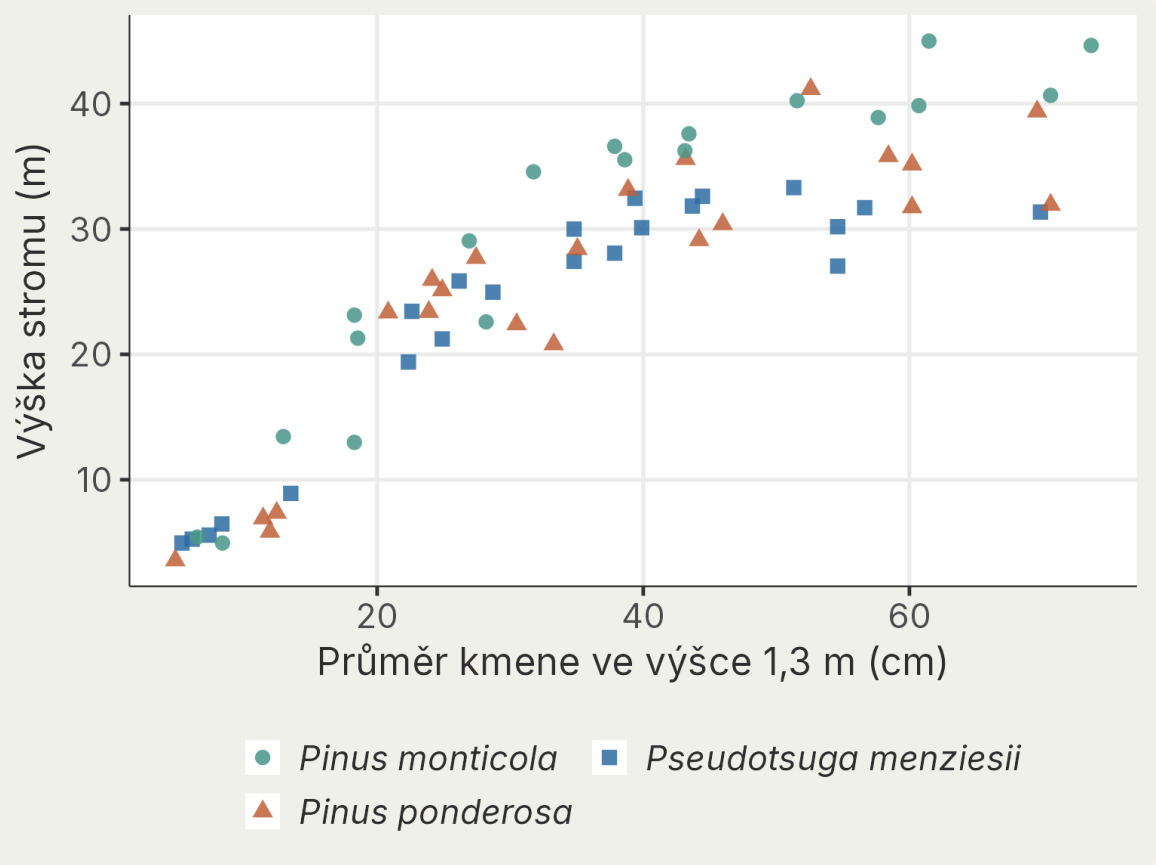

Leží residua některého druhu převážně nad nulou, nebo pod ní?

Průměrné residuum *P. monticola*: +2,7 m

Společná přímka přehlíží rozdíly mezi druhy.

# Tři představy o růstu stromů

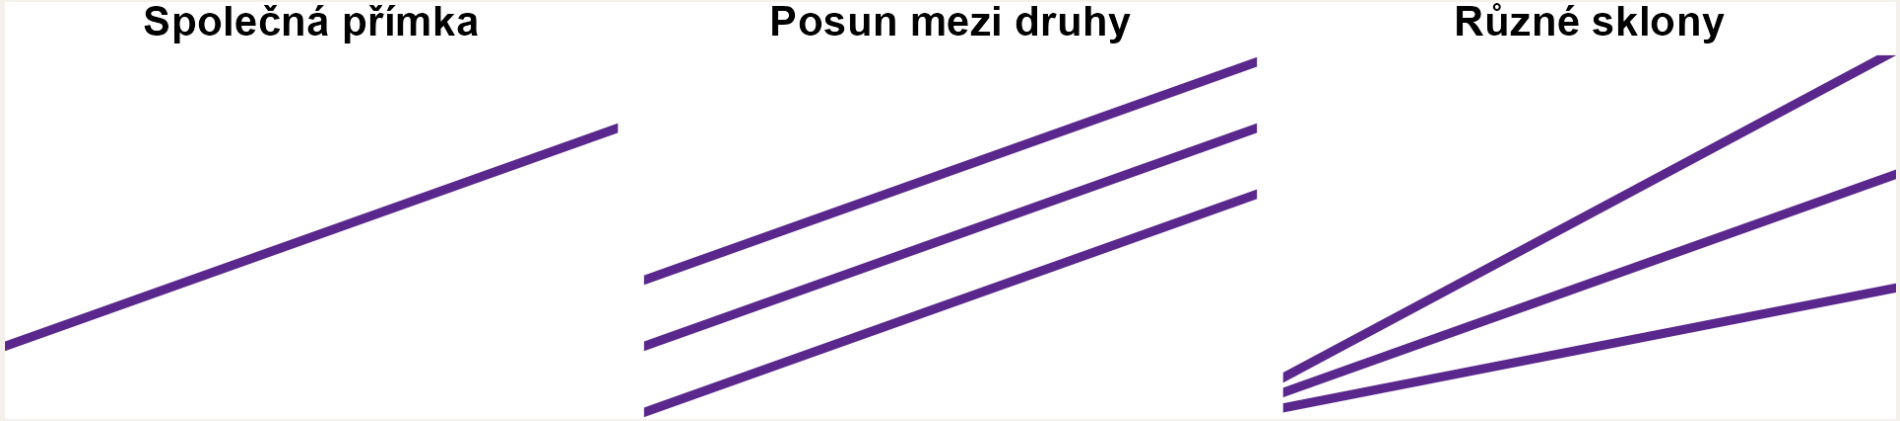
# Jaké jiné přímky by mohly stromy popsat?




**Ve dvojici:** Načrtněte dvě jiné možnosti než jednu společnou přímku.
Co by každá z nich tvrdila o stromech?

Pomůcka: modely z minulé lekce — `+` a `*`.

# Tři modely vyjadřují tři biologické představy




`vyska ~ prumer`

Všechny druhy sdílejí stejný intercept i sklon.

`vyska ~ prumer + druh`

Při stejném průměru se druhy mohou lišit výškou, sklon sdílejí.

`vyska ~ prumer * druh`

Vztah průměru a výšky se může mezi druhy lišit.

> Tuto sadu kandidátů určíme předem — z biologické otázky, ne z výsledků.

# Všechny tři modely odhadneme ze stejných 63 stromů

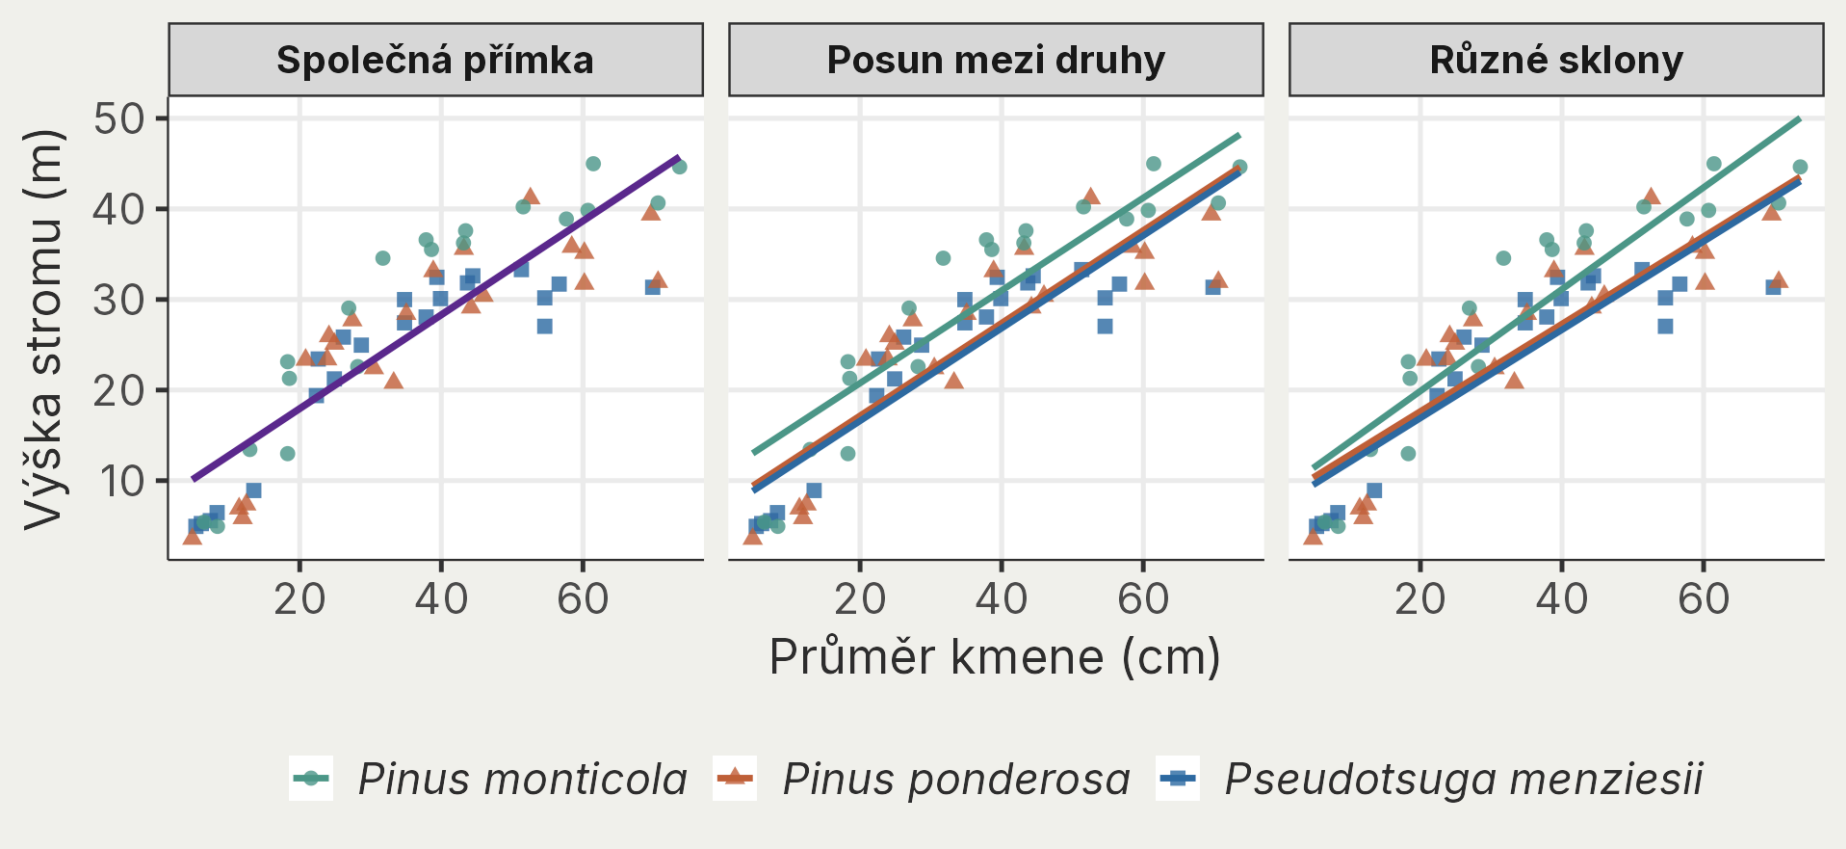
```r
# Všechny tři kandidáty zapíšeme vedle sebe
mod_spolecny <-
  lm(
    formula = vyska_stromu_m ~ prumer_kmene_cm,
    data = data_stromy
  )

mod_aditivni <-
  lm(
    formula = vyska_stromu_m ~ prumer_kmene_cm + druh_stromu,
    data = data_stromy
  )

mod_interakce <-
  lm(
    formula = vyska_stromu_m ~ prumer_kmene_cm * druh_stromu,
    data = data_stromy
  )
```

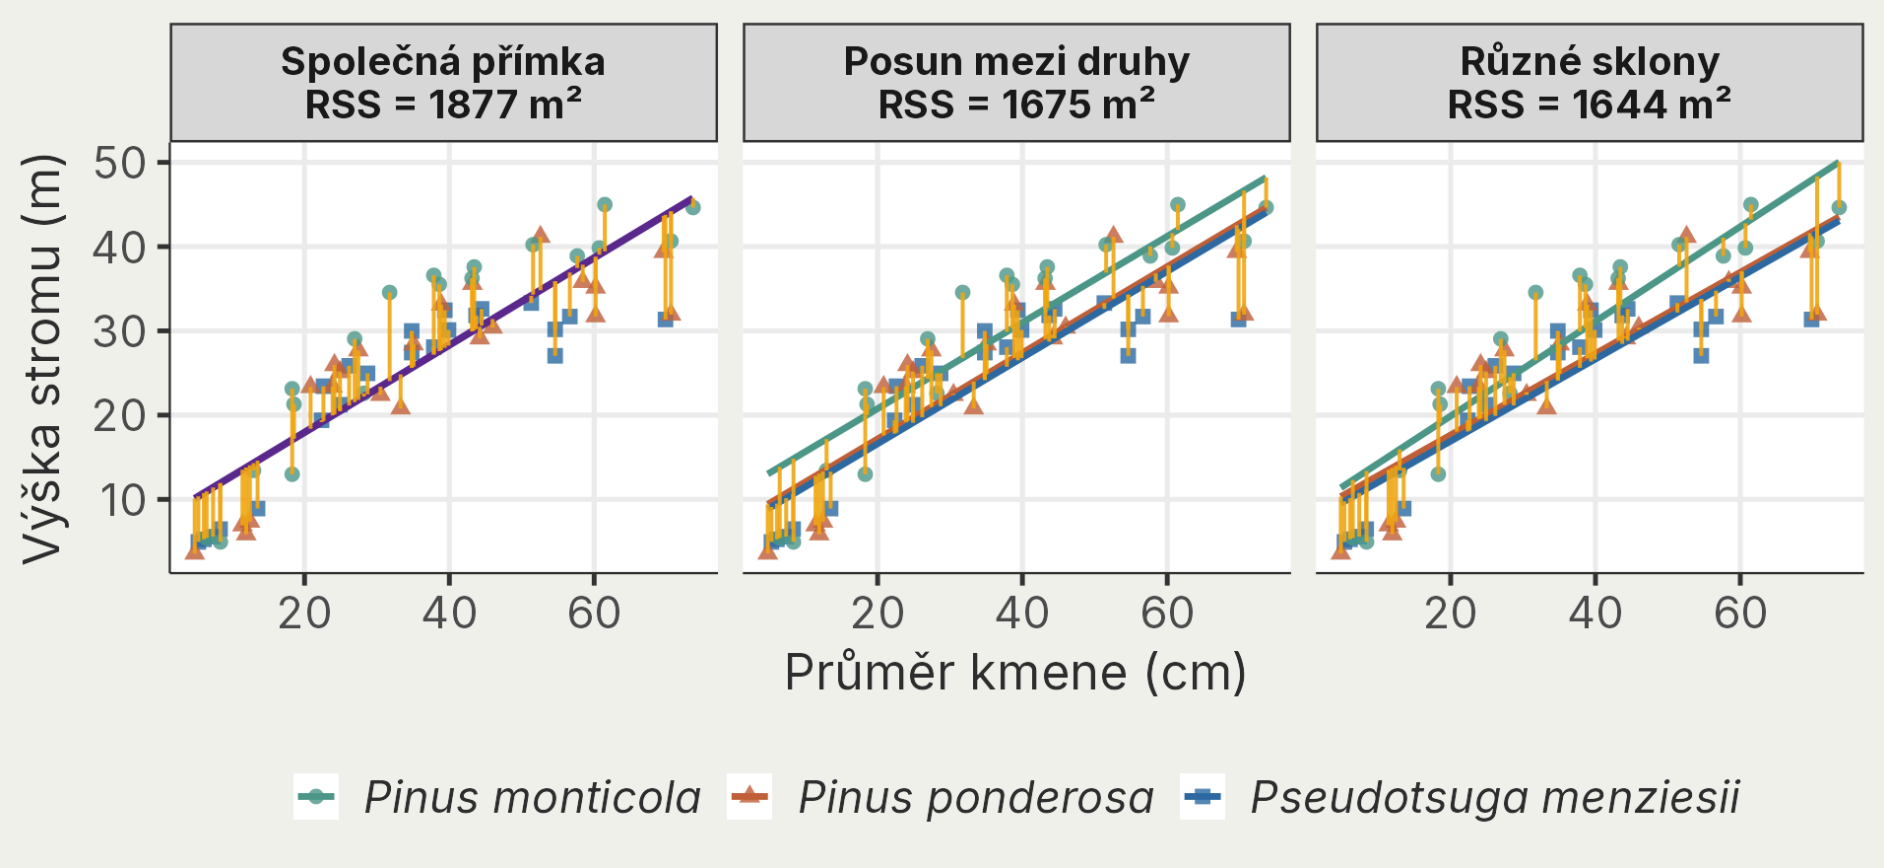
> Stejná odezva `vyska_stromu_m` · stejných 63 stromů v každém modelu

# Který model prochází nejblíže pozorovaným stromům?




**A** · Společná přímka **B** · Posun mezi druhy **C** · Různé sklony

# Nejblíže procházejí přímky s různými sklony




**Je proto nejlepší?**

# Podle čeho poznáme lepší model?

## Podle čeho byste mezi modely vybírali?

- jak těsně model odpovídá pozorovaným datům;
- kolik koeficientů potřebuje;
- zda v residuích nezůstává systematický vzorec;
- zda odpovídá biologické otázce;
- zda jeho výsledek dokážeme smysluplně interpretovat.

> Žádné jediné číslo neodpoví na všechny tyto otázky.

# Jak změřit shodu modelu s daty?

# Co už víme o součtu čtverců residuí?

**HLEDÁNÍ PŘÍMKY**

Kandidátní přímky jsme porovnávali součtem čtverců residuí.

**ZKRATKA RSS**

Stejnou veličinu jsme označili **RSS** (*residual sum of squares*).

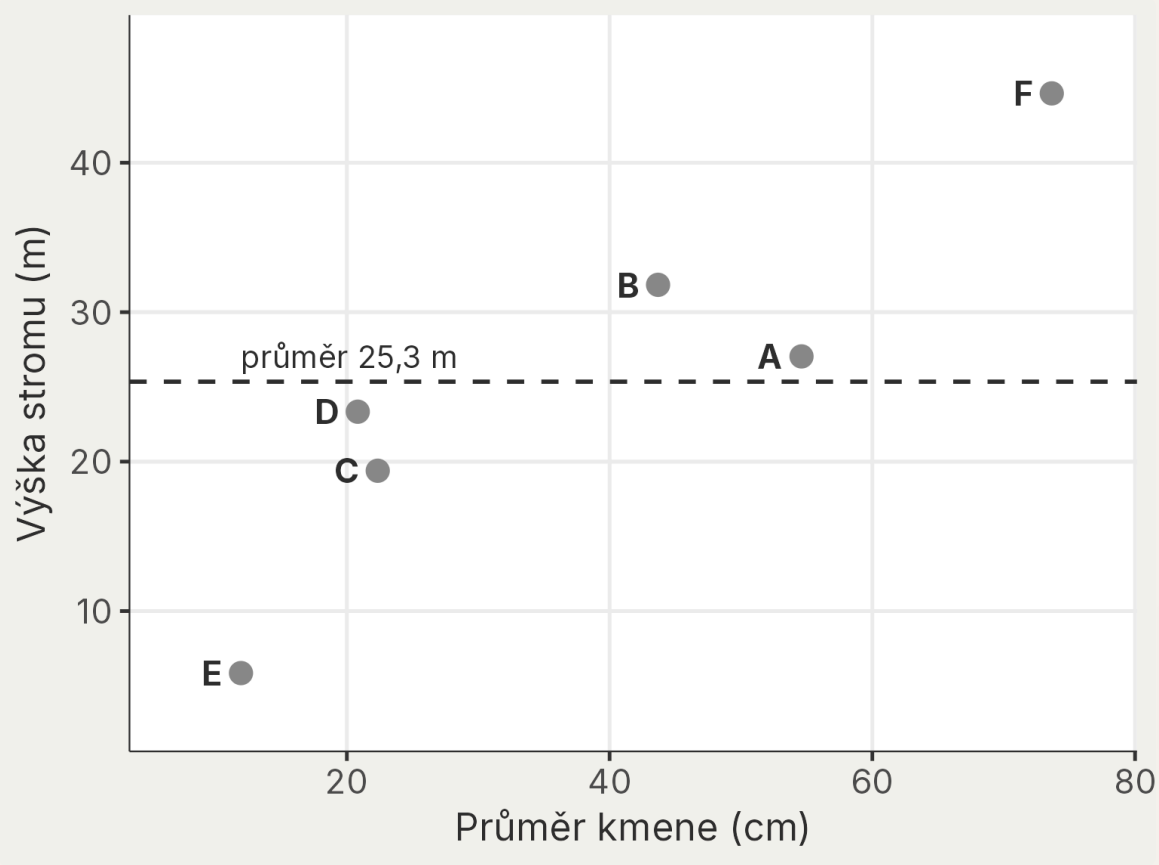
**SKUPINOVÉ PRŮMĚRY**

Skupinové průměry RSS zmenšily oproti jednomu společnému průměru.

Co se stane s RSS, když přímka prochází blíže pozorovaným bodům?

Kratší residua → menší čtverce → menší RSS = těsnější shoda s daty.

# Je přímka lepší než predikce průměrem?

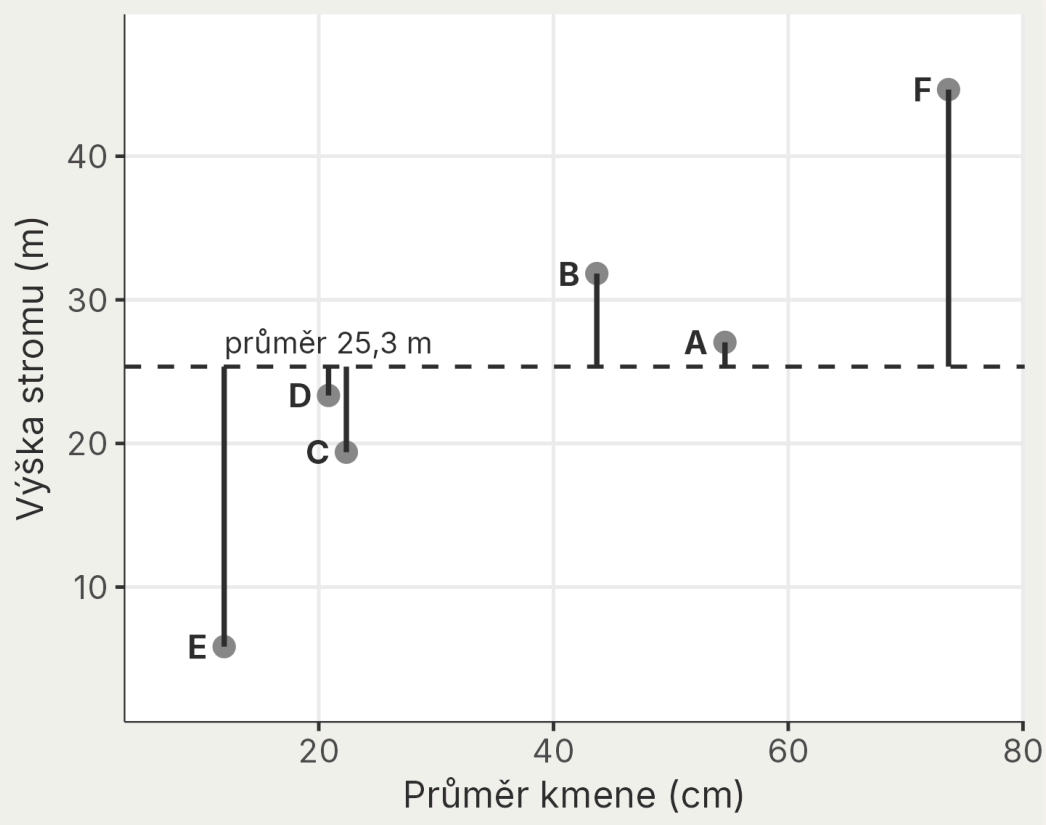



Šest skutečných stromů z tabulky.

Predikce bez prediktoru: každému stromu průměrnou výšku.

Prošla by přímka podle průměru kmene body blíže než průměr?

# Jak velké jsou rozdíly výšek kolem průměru?

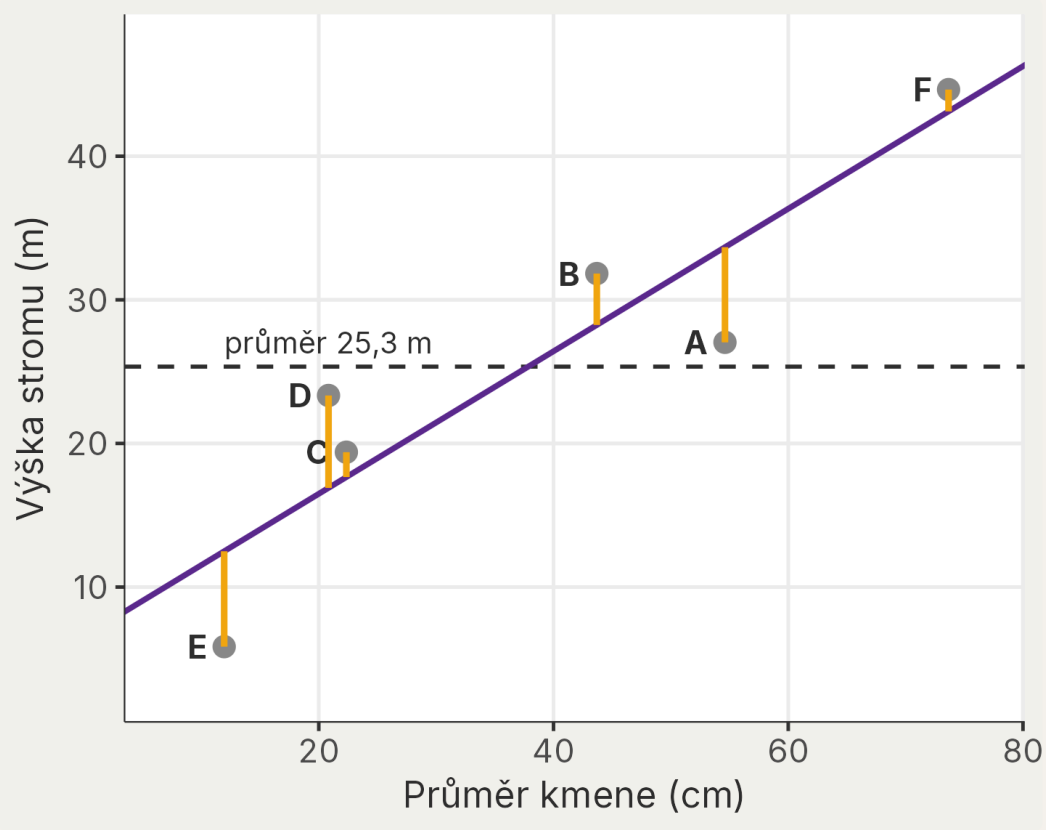



| Strom | Odchylka | Čtverec |
|---|---|---|
| A | 1,7 | 2,9 |
| B | 6,5 | 42,0 |
| C | −6,0 | 35,5 |
| D | −2,0 | 4,0 |
| E | −19,5 | 380,2 |
| F | 19,3 | 372,2 |

Součet čtverců: **836,8 m²**

Tomuto součtu říkáme **celkový součet čtverců** (*total sum of squares*).

# Kolik rozdílů zůstane po odhadnutí přímky?




| Strom | Residuum | Čtverec |
|---|---|---|
| A | −6,6 | 43,9 |
| B | 3,6 | 12,8 |
| C | 1,7 | 3,0 |
| D | 6,4 | 41,4 |
| E | −6,6 | 44,1 |
| F | 1,5 | 2,3 |

RSS: 147,6 m² · celkový: 836,8 m²

Který strom leží nejvýše nad přímkou? A který nejvíce přispívá k RSS?
Strom D; k RSS nejvíce E (rozhoduje velikost, ne znaménko).

# Jakou část rozdílů přímka zachytila?

$$\text{zachycený podíl} = 1 - \frac{\text{součet čtverců residuí}}{\text{celkový součet čtverců}}$$

Jaká část rozdílů ve výšce zůstala a jakou část přímka zachytila? Dosaďte RSS 147,6 m² a celkový součet čtverců 836,8 m².

$$\text{zachycený podíl} = 1 - \frac{147{,}6}{836{,}8}$$

$$\text{zachycený podíl} = 0{,}824$$

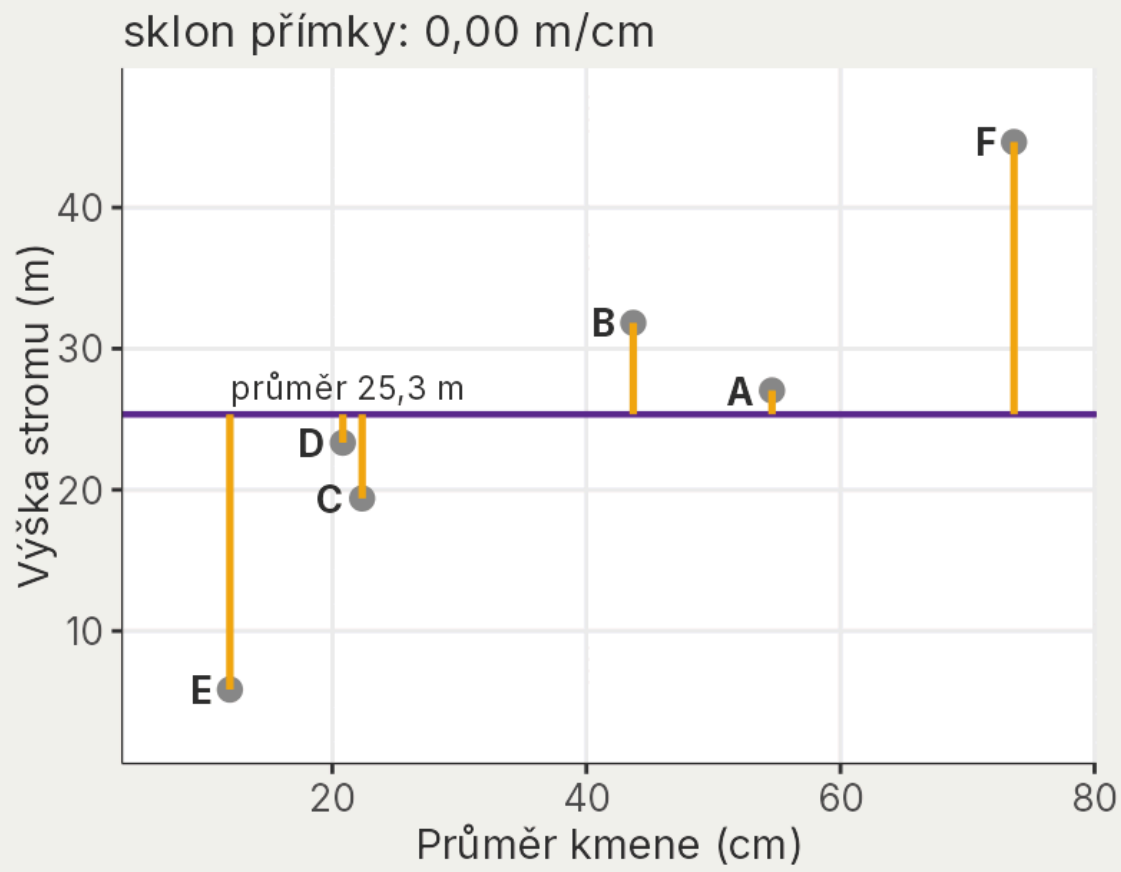
# Zachycený podíl se jmenuje $R^2$

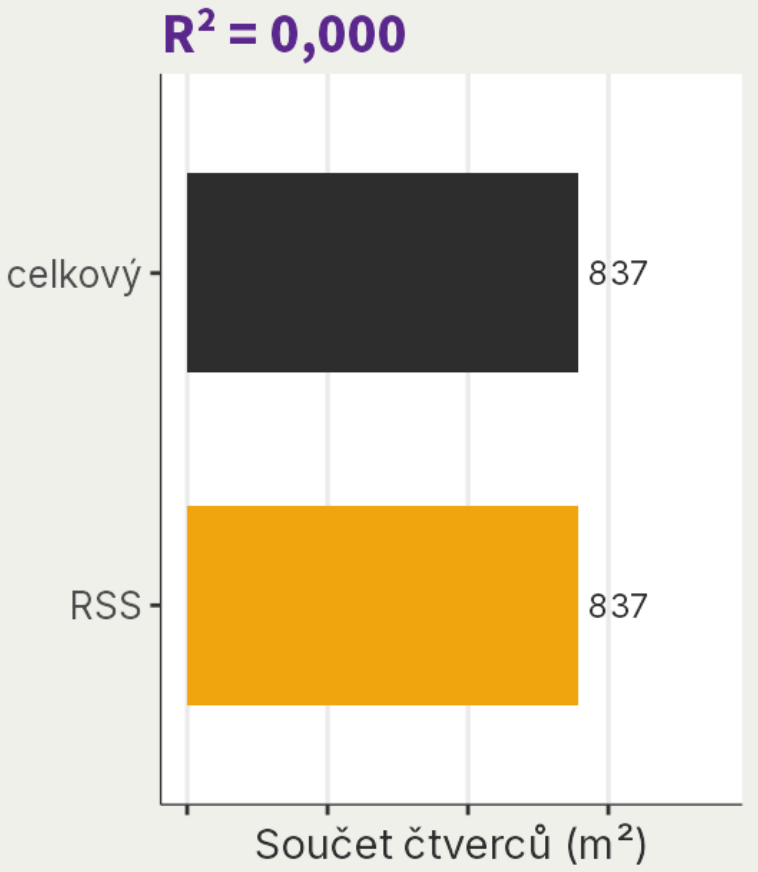
**KOEFICIENT DETERMINACE $R^2$ (*COEFFICIENT OF DETERMINATION*)**

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{total}}}$$

- $SS_{\text{res}}$ — součet čtverců residuí (RSS) od odhadnuté přímky;
- $SS_{\text{total}}$ — celkový součet čtverců odchylek od průměru;
- u šesti stromů: $R^2 = 0{,}824$.

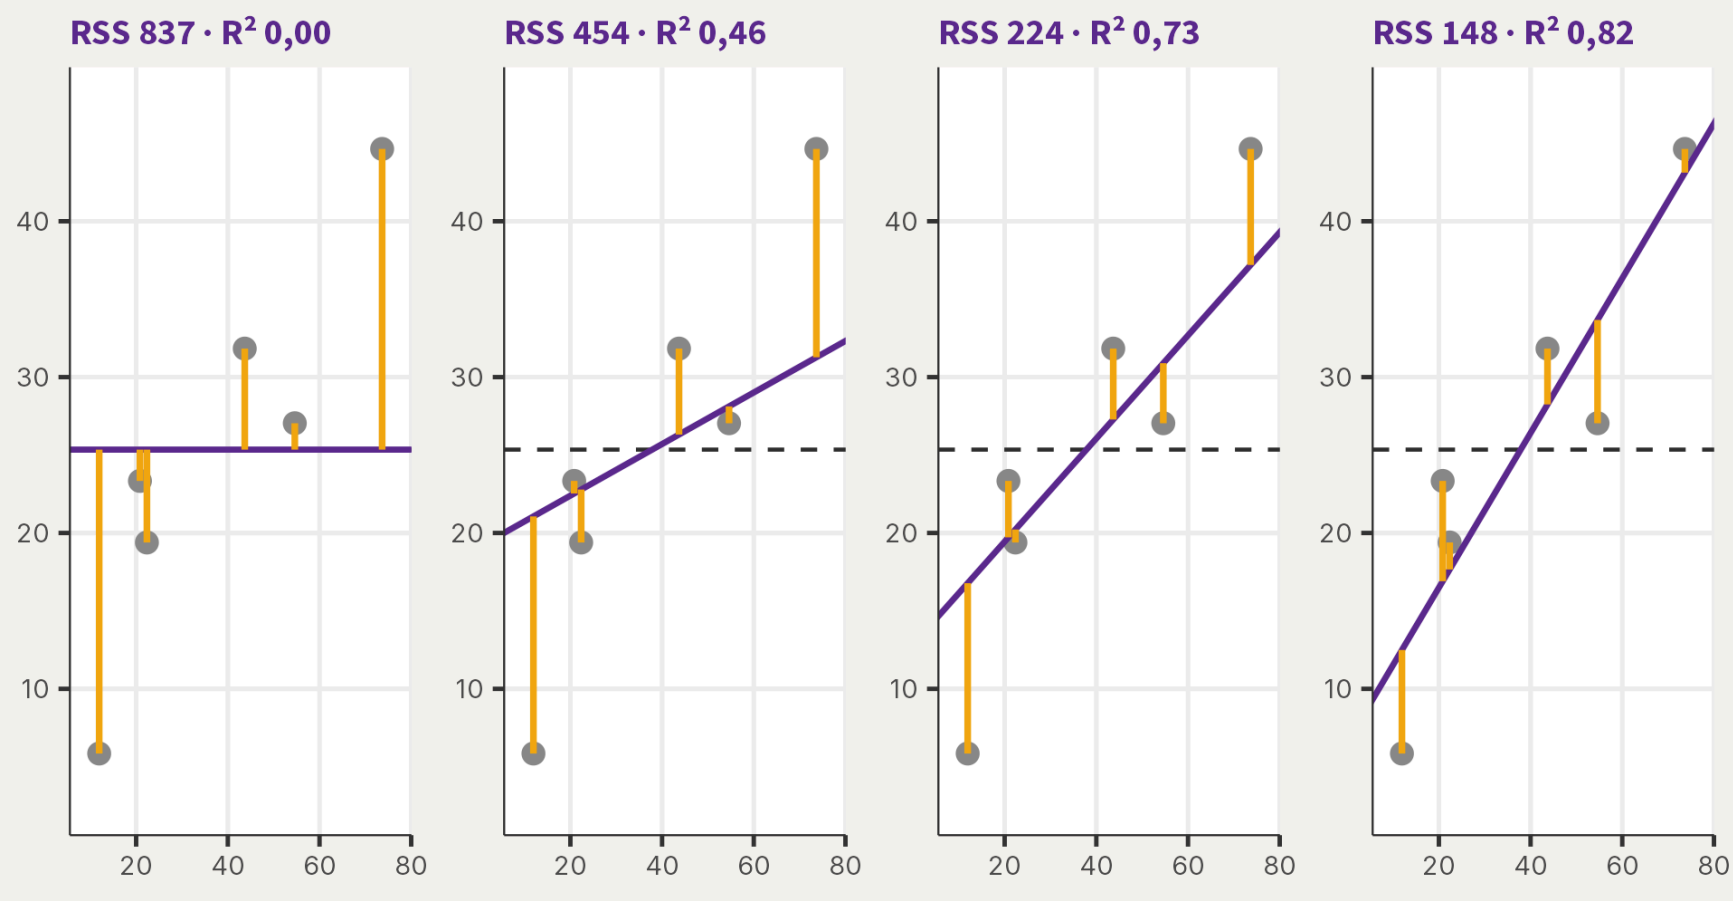
# Jak se mění RSS a $R^2$, když přímku natáčíme?




Sledujte oranžové úsečky a sloupec RSS: kdy je $R^2$ nulové a kdy největší?

# Stejných šest stromů, čtyři natočení přímky




Vodorovná přímka = predikce průměrem: $R^2 = 0$. Odhadnutá přímka: nejmenší RSS, a proto největší $R^2$.

# Dává `summary()` stejné $R^2$ pro všech 63 stromů?

$$R^2 = 1 - \frac{1877{,}4}{8084{,}6} = 0{,}768$$

```
1  summary(object = mod_spolecny)$r.squared
```

```
[1] 0.7677804
```

`Multiple R-squared` ve výpisu je tentýž výpočet — nic nového.

## Společná přímka má $R^2 = 0{,}768$. Co to znamená?

**A**
Model správně predikoval 76,8 % stromů.

**B**
Model zachytil 76,8 % variability výšky kolem průměru v těchto datech.

**C**
S pravděpodobností 0,768 je model pravdivý.

Přesvědčte souseda, proč jste vybrali svoji možnost.

Obhajitelná je B: $R^2$ popisuje podíl zachycené variability v datech, ze kterých byl model odhadnut.

# Co $R^2$ popisuje a na co nestačí?

**$R^2$ POPISUJE**

- podíl variability odezvy zachycený modelem;
- ve stejných datech, na kterých byl model odhadnut.

**$R^2$ NEŘÍKÁ**

- zda model splňuje předpoklady;
- zda je vztah příčinný;
- jak dobře model poslouží pro nové stromy;
- zda je to nejlepší z našich kandidátů?

# Pomáhá každý koeficient navíc?

# Co udělá $R^2$ po přidání druhu a interakce?

`prumer` → `prumer + druh` → `prumer * druh`

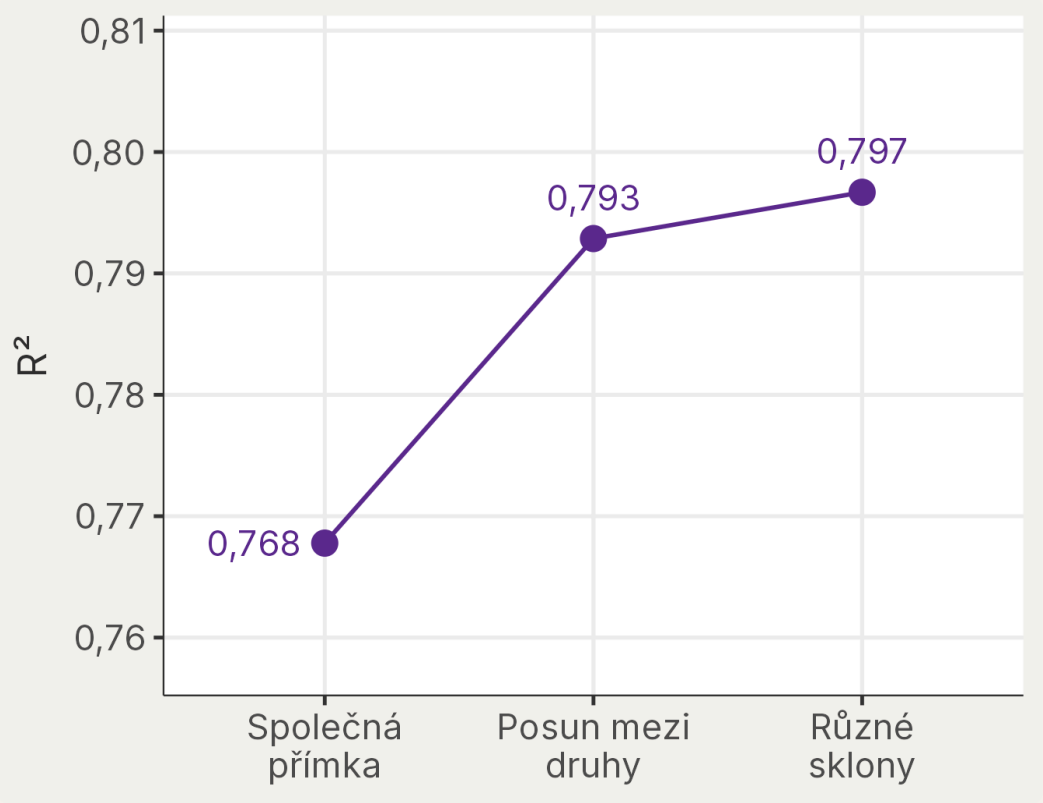
**Co se stane s $R^2$, když přidáme druh a interakci?**

**A** · $R^2$ poroste

**B** · $R^2$ může klesnout

**C** · $R^2$ zůstane stejné

# $R^2$ po přidání členů neklesne




| Model | k | RSS |
|---|---|---|
| Společná přímka | 2 | 1877 |
| Posun mezi druhy | 4 | 1675 |
| Různé sklony | 6 | 1644 |

Složitější model umí zopakovat jednodušší, a tak $R^2$ nejhůř zůstane stejné; klesnout nemůže.

**Vyšší $R^2$ není automatické vítězství.** I téměř zbytečný prediktor $R^2$ nesníží.

# Které koeficienty jednotlivé modely odhadují?

Který seznam patří společné přímce, který posunu mezi druhy a který různým sklonům?

**A· POSUN MEZI DRUHY · K = 4**

`(Intercept)`
`prumer_kmene_cm`
`druh_stromuPinus ponderosa`
`druh_stromuPseudotsuga menziesii`

**B· SPOLEČNÁ PŘÍMKA · K = 2**

`(Intercept)`
`prumer_kmene_cm`

**C· RŮZNÉ SKLONY · K = 6**

`(Intercept)`
`prumer_kmene_cm`
`druh_stromuPinus ponderosa`
`druh_stromuPseudotsuga menziesii`
`prumer_kmene_cm:druh_stromuPinus ponderosa`
`prumer_kmene_cm:druh_stromuPseudotsuga menziesii`

# Jak $R^2$ opravit za počet koeficientů?

adjustované $R^2$ = 1 − nezachycený podíl × úprava za počet stromů a koeficientů

Posun mezi druhy: $R^2 = 0{,}793$, $n = 63$ stromů, $k = 4$ koeficienty

$$R^2_{\text{adj}} = 1 - (1 - 0{,}793) \times \frac{63 - 1}{63 - 4} = 0{,}782$$

**Adjustované $R^2$** (*adjusted R-squared*):

$$R^2_{\text{adj}} = 1 - \left(1 - R^2\right) \times \frac{n - 1}{n - k}$$

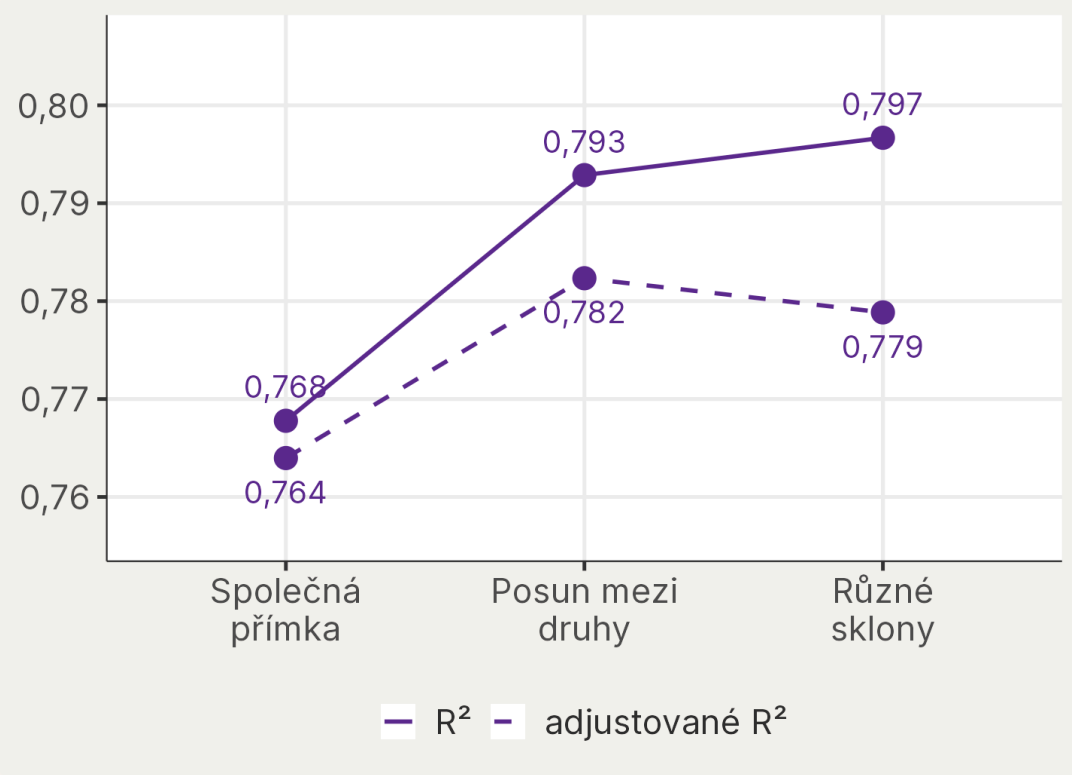
# Co udělá adjustované $R^2$ po přidání interakce?

Posun mezi druhy → Různé sklony: $R^2$ 0,793 → 0,797 · $k$ 4 → 6 · $n$ = 63

**A** · adjustované $R^2$ vzroste

**B** · adjustované $R^2$ klesne

# Adjustované $R^2$ po přidání interakce klesne




Dva sklony navíc zlepšily $R^2$ jen o **0,004**.

Zlomek $\frac{n-1}{n-k}$ vzrostl víc, než se zmenšil nezachycený podíl → **úprava zvítězila**.

# Co už o třech modelech víme?

Jak poznáme, že je model dobrý?

**UŽ UMÍME ŘÍCT**

- $R^2$ měří shodu s daty a vždy upřednostní nejpružnější model.
- Adjustované $R^2$ upřednostní posun mezi druhy.

**ZATÍM NEVÍME**

- Kdy se složitost obecně vyplatí?
- Vypadají residua vybraného modelu v pořádku?

# Kdy se složitost vyplatí?

# Vyplatí se model šitý na míru?



Ilustrace vytvořená pomocí AI.

**Ve dvojici:** Posun mezi druhy a různé sklony popisují stromy téměř stejně dobře ($R^2$ 0,793 a 0,797). První potřebuje 4 koeficienty, druhý 6.
Který byste upřednostnili? Co byste chtěli vědět, než se rozhodnete?

Princip úspornosti (*parsimony*)

Složitější model upřednostníme jen tehdy, když dostatečně zlepší shodu s daty.

# AIC váží shodu i složitost

**AKAIKEHO INFORMAČNÍ KRITÉRIUM (*AKAIKE INFORMATION CRITERION*, AIC)**

- lepší shoda AIC snižuje;
- každá odhadovaná veličina navíc AIC zvyšuje;
- preferujeme nižší AIC.

```
1  AIC(object = mod_spolecny)
```

```
[1] 398.64
```

AIC není podíl a nemá stejnou škálu jako $R^2$.

# Model má AIC 398,64. Je to dobrý model?

**A** · Ano, AIC je nízké.

**B** · Ne, AIC je vysoké.

**C** · Z jedné hodnoty to nepoznáme.

AIC je relativní. Porovnáváme jen modely se stejnou odezvou, stejnými pozorováními a stejným předpokladem o rozdělení residuí.

# O kolik je AIC každého kandidáta vyšší než nejnižší?

$$\Delta\text{AIC} = \text{AIC kandidáta} - \text{nejnižší AIC v sadě}$$

Společná přímka: $398{,}64 - 395{,}44 = 3{,}20$

| Model | AIC | ΔAIC |
|---|---|---|
| Společná přímka | 398,64 | 3,20 |
| Posun mezi druhy | 395,44 | 0,00 |
| Různé sklony | 398,27 | 2,83 |

Posun mezi druhy má ΔAIC = 0 · univerzální práh nepoužíváme

# Ukazují $R^2$, adjustované $R^2$ a AIC na stejný model?

| Model | k | $R^2$ ↑ | adj. $R^2$ ↑ | AIC ↓ |
|---|---|---|---|---|
| Společná přímka | 2 | 0,768 | 0,764 | 398,64 |
| Posun mezi druhy | 4 | 0,793 | 0,782 | 395,44 |
| Různé sklony | 6 | 0,797 | 0,779 | 398,27 |

**Ve dvojici:** Proč $R^2$ upřednostní jiný model než adjustované $R^2$ a AIC?

$R^2$ hodnotí jen shodu. Adjustované $R^2$ a AIC penalizují složitost — dva sklony navíc se nevyplatily. Nejsou to tři hlasy o pravdě.

# Nejlépe podporovaný kandidát nemusí být dobrý model



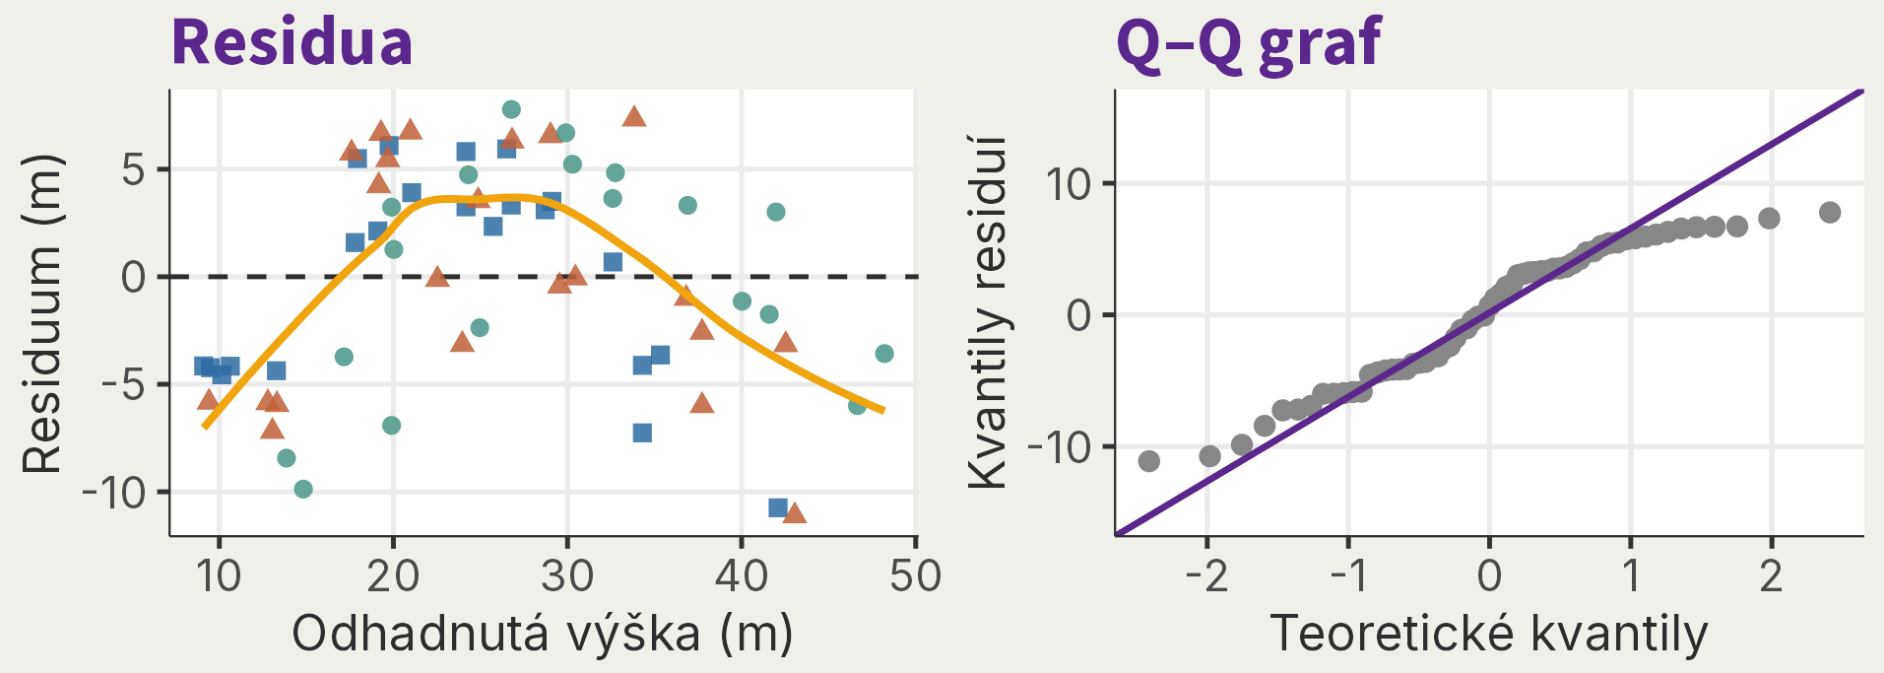
Ilustrace vytvořená pomocí AI.

Porovnání řadí jen modely, které jsme do sady zařadili.
Neříká, že je vítěz obecně dobrý.
Model, který jsme vůbec neposuzovali, může stromy popsat lépe.

## Proto vybraný model ještě zkontrolujeme.

# Obstojí vybraný model?

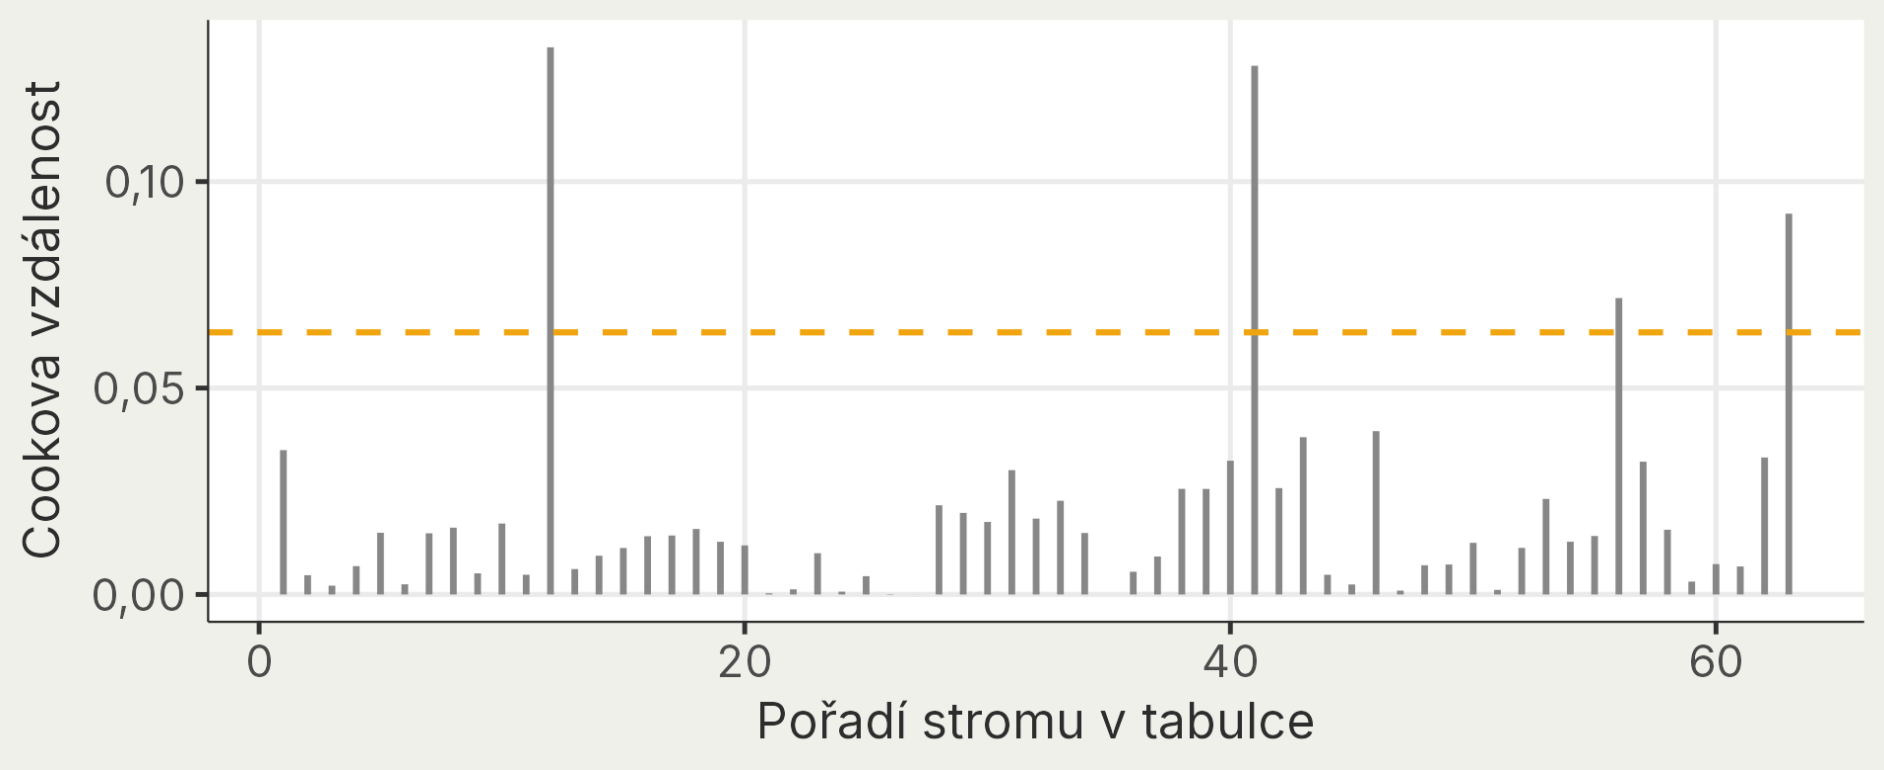
# Zůstává v residuích modelu Posun mezi druhy nějaký vzorec?




**Ve dvojici:** Leží residua v celém rozsahu odhadnutých výšek náhodně kolem nuly?

Oranžová křivka jen vyhlazuje průběh bodů, aby byl vzor lépe vidět: residua tvoří oblouk · Q–Q graf není přímý.

# Které stromy ovlivňují model nejvíc?




Cookova vzdálenost: o kolik by se odhadnuté hodnoty změnily, kdyby strom chyběl. Nad orientační čarou $4/n$: 4 stromy.

Důvod stromy prověřit — ne je automaticky odstranit.

# Obhajte model dvěma větami

**40 S SAMI · VE DVOJICI POROVNEJTE**

„Ze tří kandidátů vybíráme model ____, protože ____.“
„Omezením tohoto závěru je ____.“

Opřete se aspoň o dva různé druhy důkazů: shodu, složitost, diagnostiku, biologický smysl.

# Který model lze pro tyto stromy nejlépe obhájit?

**POSUN MEZI DRUHY**

- zachytí rozdíly mezi druhy, které společná přímka přehlíží;
- nejvyšší adjustované $R^2$ (0,782) a nejnižší AIC.

**OMEZENÍ**

- vybírali jsme jen ze tří kandidátů;
- residua tvoří oblouk: přímka nevystihuje tvar vztahu;
- 63 stromů, Q–Q graf není přímý;
- pozorovací data: nejde o příčinný efekt druhu.

Dobrý model nepoznáme podle jediného čísla. Obhajoba propojuje otázku, shodu, složitost, diagnostiku a interpretovatelnost.

# Jak porovnávat modely bez automatického hledání?

1. Položte biologickou otázku.
2. Prohlédněte a zobrazte data.
3. Určete malou sadu zdůvodněných kandidátů.
4. Použijte stejnou odezvu a stejná pozorování.
5. Porovnejte přímky, residua, $R^2$, adjustované $R^2$ a AIC.
6. Zkontrolujte předpoklady a vlivná pozorování.
7. Obhajte závěr a pojmenujte omezení.

Automatické přidávání a odebírání členů vytvoří mnoho modelů, ale neurčí, které dávají biologický smysl.

# Co si odnést

- $R^2$ = podíl zachycené variability; počítá se z celkového součtu čtverců a RSS.
- Po přidání členu $R^2$ neklesne, a proto samo model nevybírá.
- Adjustované $R^2$ a AIC penalizují složitost, každé jinak; AIC je relativní.
- Kandidáty určujeme předem: stejná odezva, stejná pozorování.
- Obhajoba spojuje několik druhů důkazů včetně diagnostiky a omezení.

# Co když žádná přímka nestačí?



Všechny tři kandidáty jsme kreslili jako přímky — a residua přesto tvoří oblouk.

Ilustrace vytvořená pomocí AI.

**Jak popsat vztah, který není přímkový?**